D'un POC RAG à un MVP scalable

Agent conversationnel culturel — Pays de la Loire

Morgan Le Gall · juin 2026 · MVP RAG Puls-Events

D'un POC RAG à un MVP scalable

Agent conversationnel culturel — Pays de la Loire

RAG hybride | Mémoire | Géo | Web temps réel | Monitoring

Morgan Le Gall · juin 2026 · MVP RAG Puls-Events

D'un POC RAG à un MVP scalable

Agent conversationnel culturel — Pays de la Loire

1 - Point de départ
2 - Le besoin
3 - Du POC au MVP
4 - L’architecture du MVP
5 - Justification
6 - Monitoring
7 - Pilotage
8 - Synthèse

Morgan Le Gall · juin 2026 · MVP RAG Puls-Events

Point de départ

L'existant — le POC RAG Puls-Events

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS

- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS

- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)

- **Périmètre cadré**
  événements Pays de la Loire < 1 an

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Ses limites = nos 4 défis

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Ses limites = nos 4 défis

1. **Stateless**
   aucune mémoire de conversation

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Ses limites = nos 4 défis

1. **Stateless**
   aucune mémoire de conversation
2. **Pas de contexte géographique**
   impossible de filtrer par distance

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Ses limites = nos 4 défis

1. **Stateless**
   aucune mémoire de conversation
2. **Pas de contexte géographique**
   impossible de filtrer par distance
3. **Connaissance figée**
   pas d'accès web temps réel

Point de départ

L'existant — le POC RAG Puls-Events

Ce qui fonctionne déjà

- **RAG fonctionnel**
  LangChain + Mistral + FAISS
- **Retriever hybride**
  BM25 (lexical) + dense (embeddings)
- **Périmètre cadré**
  événements Pays de la Loire < 1 an
- **Réponses sourcées**
  citations des documents récupérés

Ses limites = nos 4 défis

1. **Stateless**
   aucune mémoire de conversation
2. **Pas de contexte géographique**
   impossible de filtrer par distance
3. **Connaissance figée**
   pas d'accès web temps réel
4. **Aucun monitoring**
   ni qualité, ni coût, ni satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Le besoin

Quatre défis + des contraintes transverses

1

Mémoire conversationnelle

Historique de session + personnalisation persistante

2

Contexte géographique

Recherche par rayon / distance (« à 20 km de moi »)

3

Recherche web temps réel

Compléter le RAG sur l'actualité la plus fraîche

4

Monitoring

Qualité du RAG, coût par requête, satisfaction

Contraintes transverses

Souveraineté FR / RGPD **Scalabilité multi-instances** **Budget MVP maîtrisé**

Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins

Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins

BATCH — construction de l'index

RUNTIME — réponse à une question

Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins

hérité (POC RAG Puls-Events)

BATCH — construction de l'index

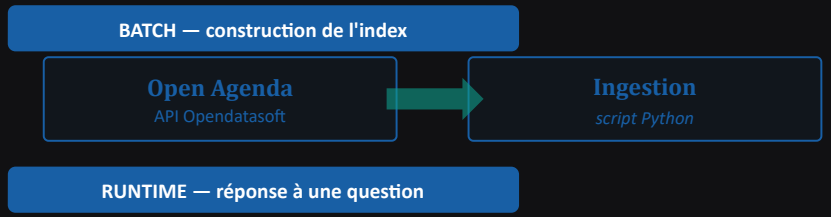
Open Agenda
API Opendatasoft

RUNTIME — réponse à une question

Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins

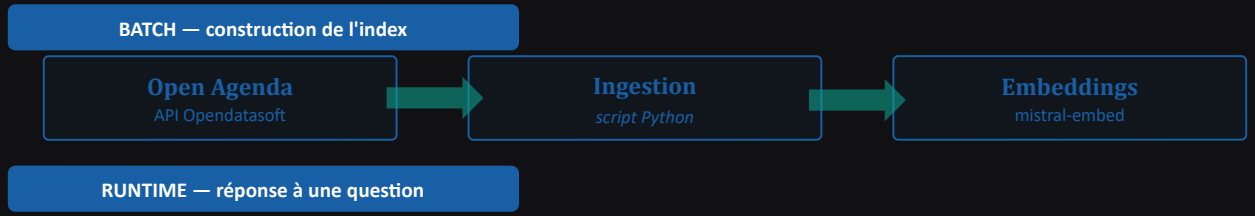
hérité (POC RAG Puls-Events)



Du POC au MVP

hérité (POC RAG Puls-Events)

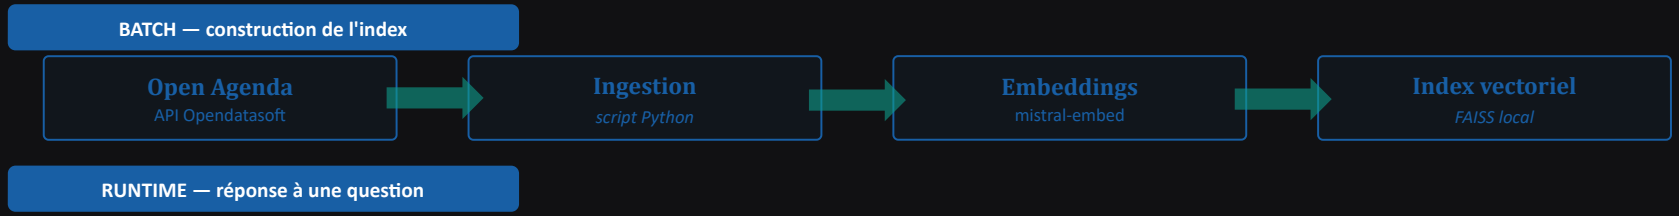
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

hérité (POC RAG Puls-Events)

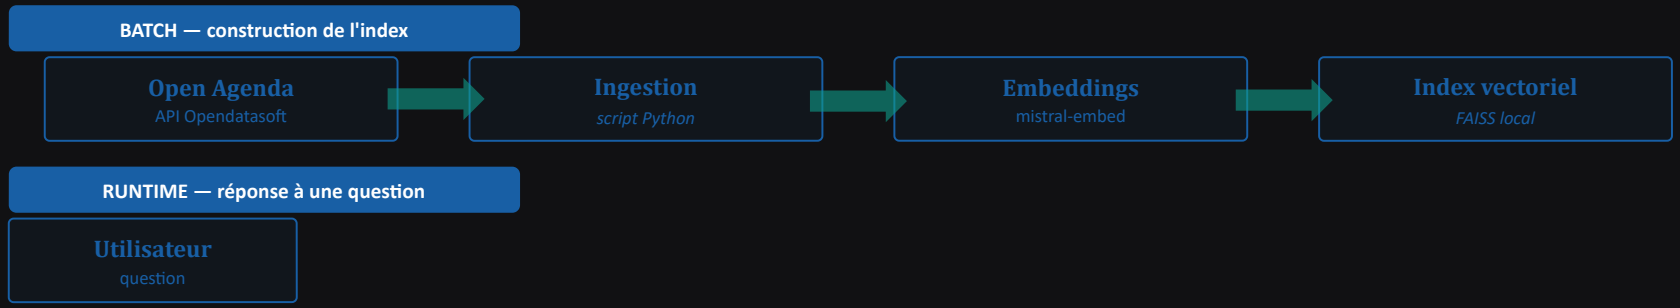
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

hérité (POC RAG Puls-Events)

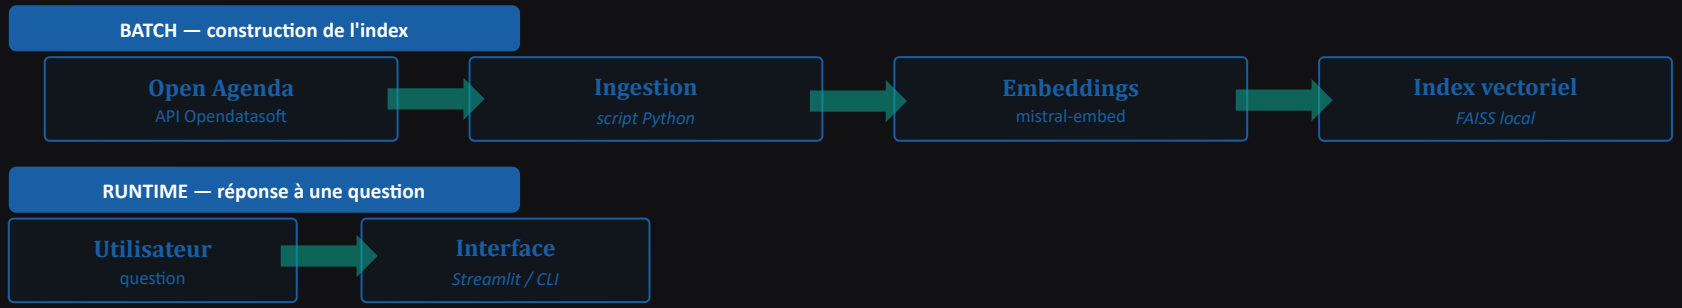
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

hérité (POC RAG Puls-Events)

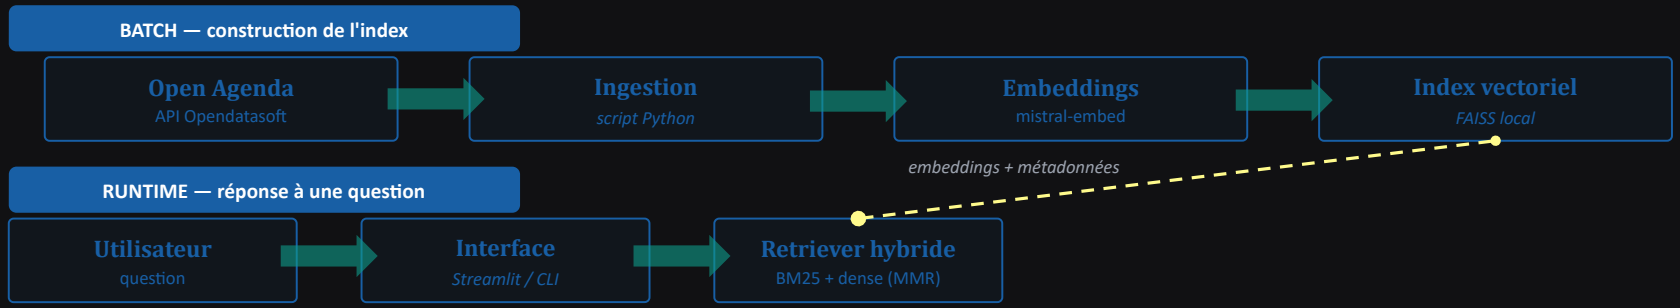
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

hérité (POC RAG Puls-Events)

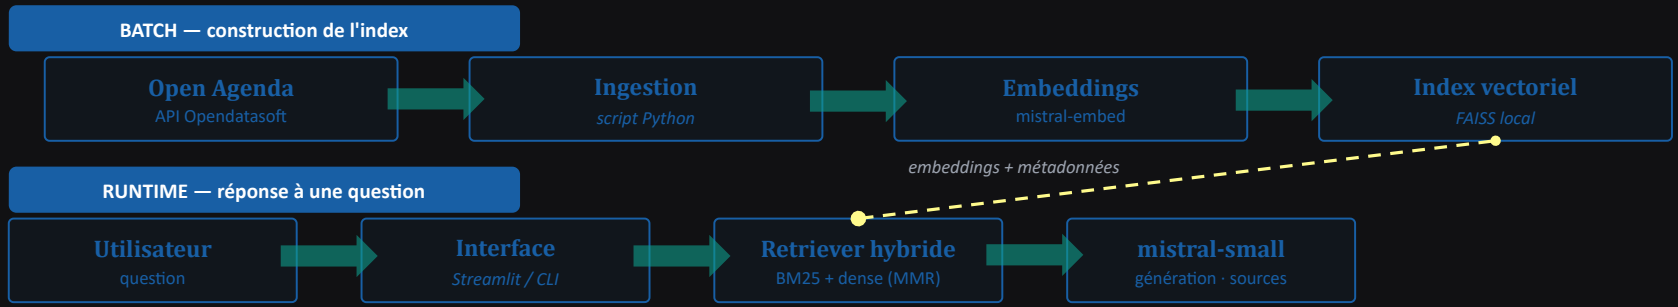
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

hérité (POC RAG Puls-Events)

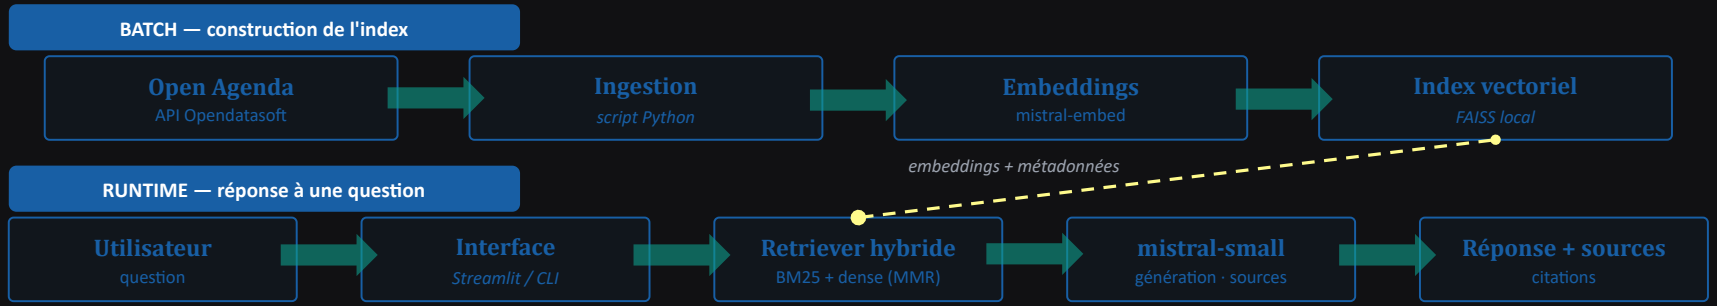
Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

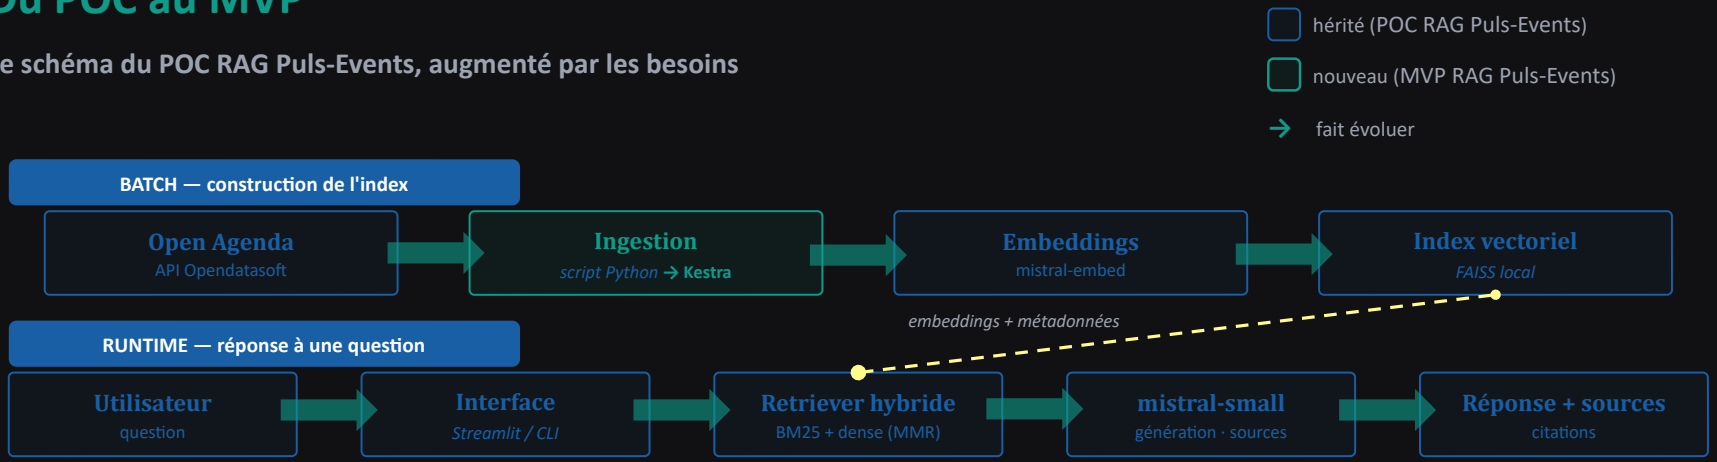
hérité (POC RAG Puls-Events)

Le schéma du POC RAG Puls-Events, augmenté par les besoins



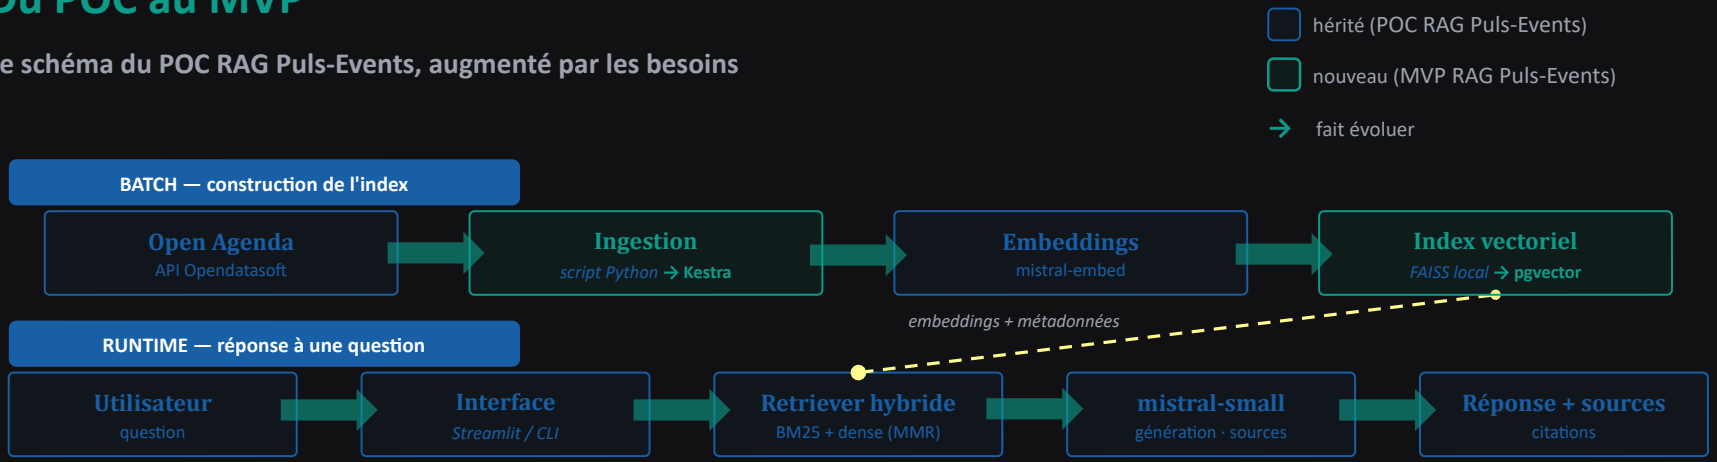
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



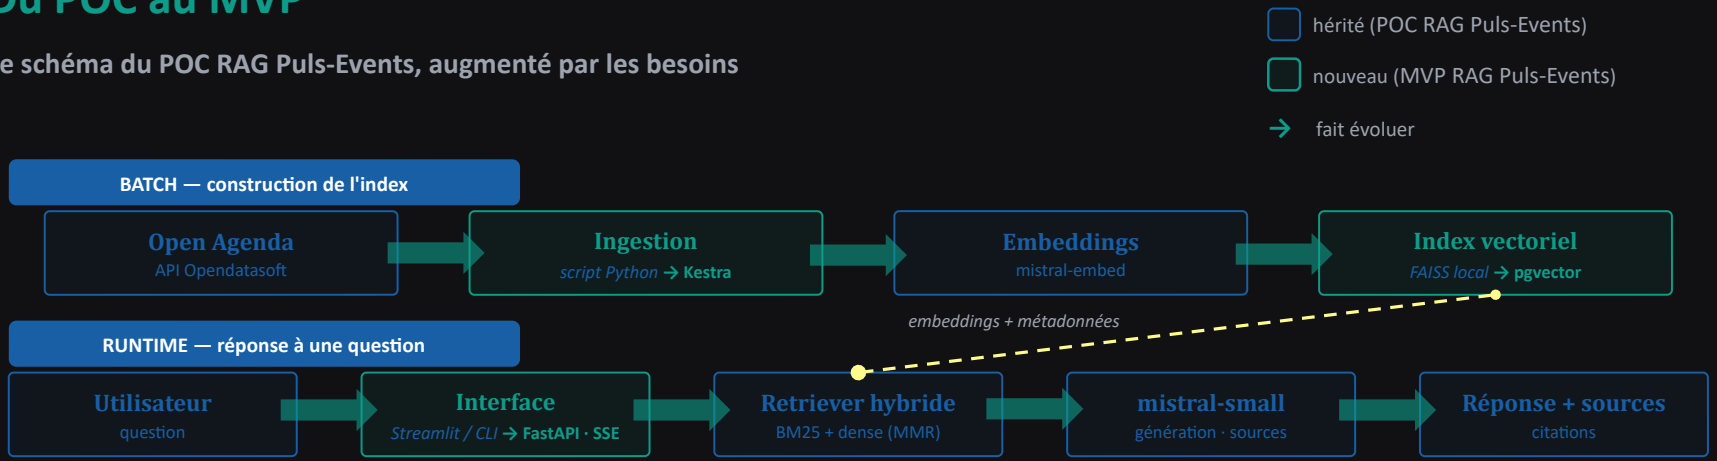
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



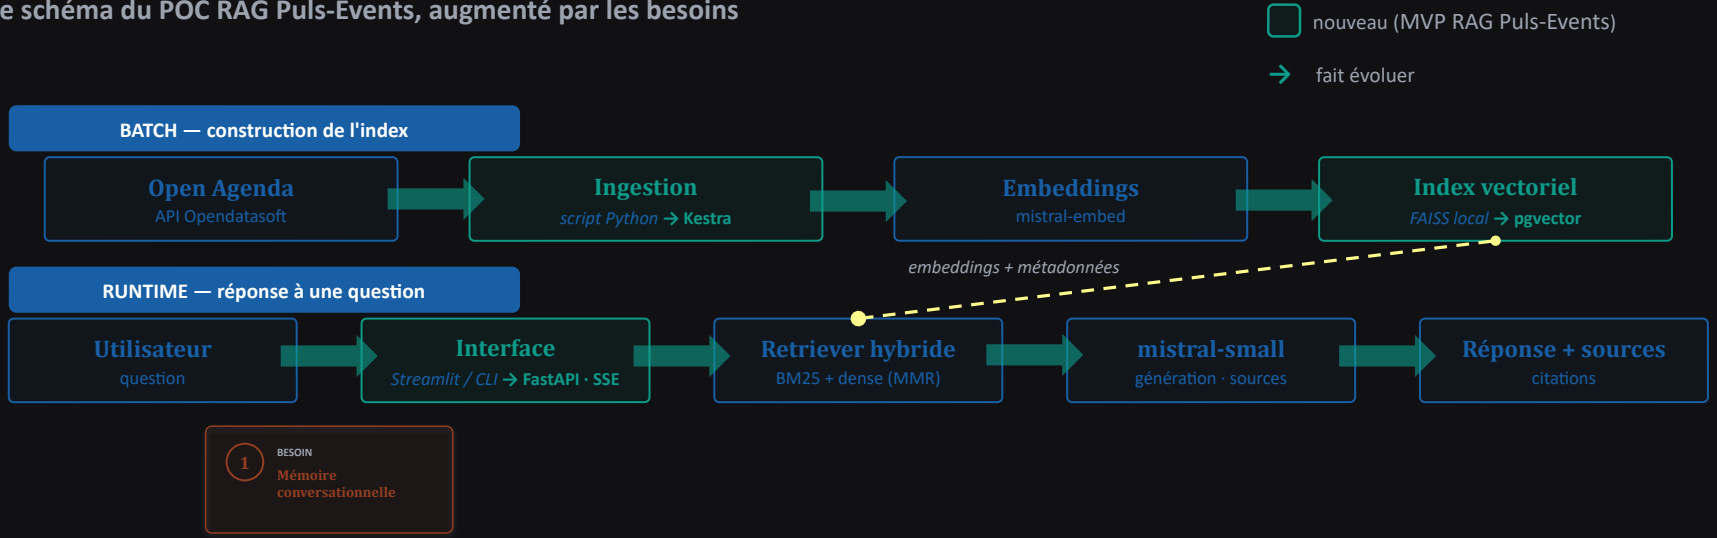
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



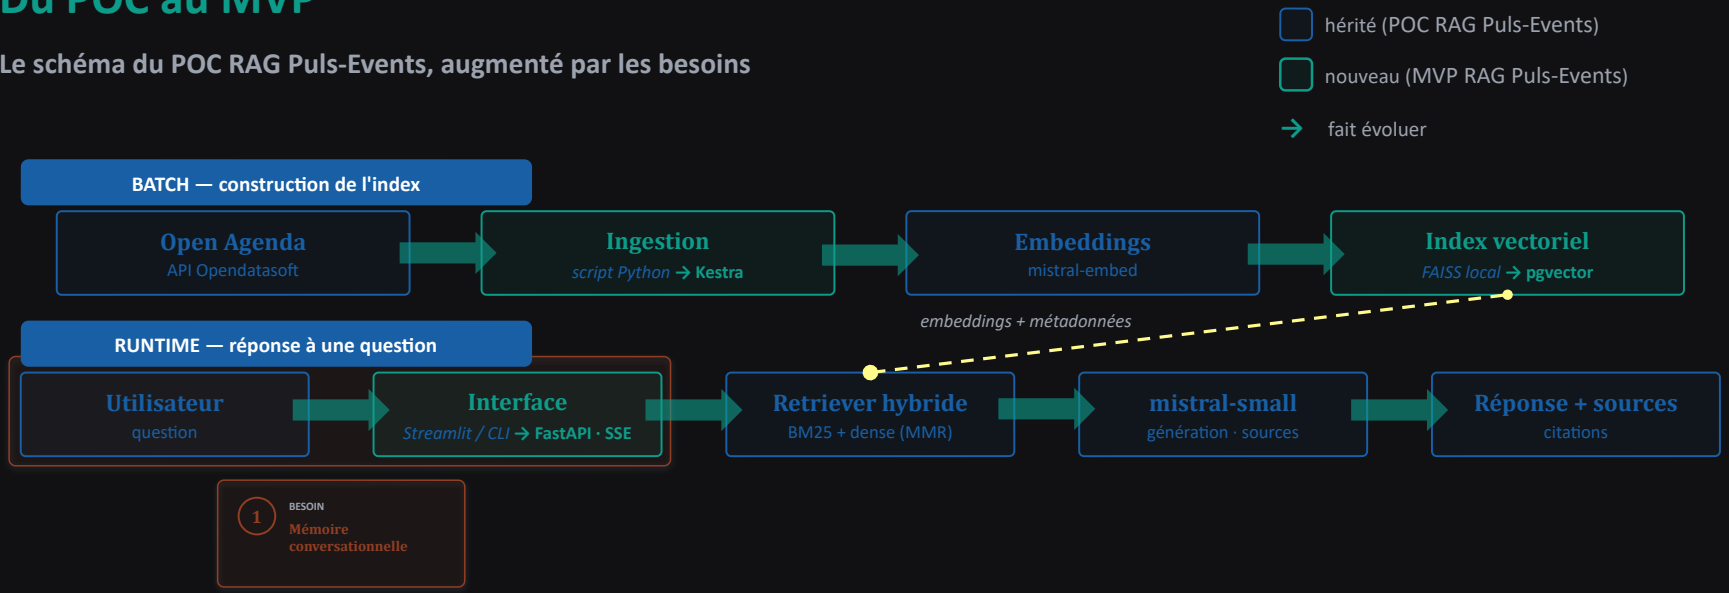
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



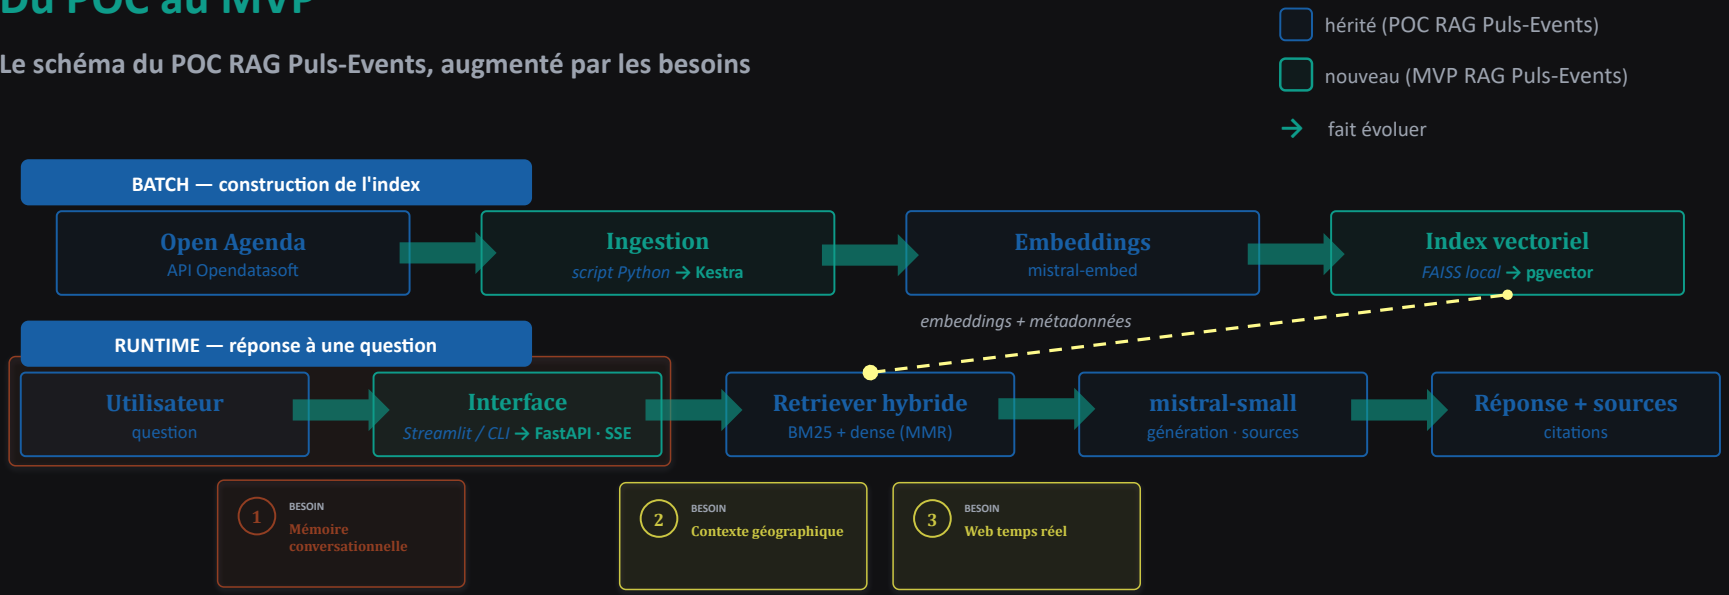
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



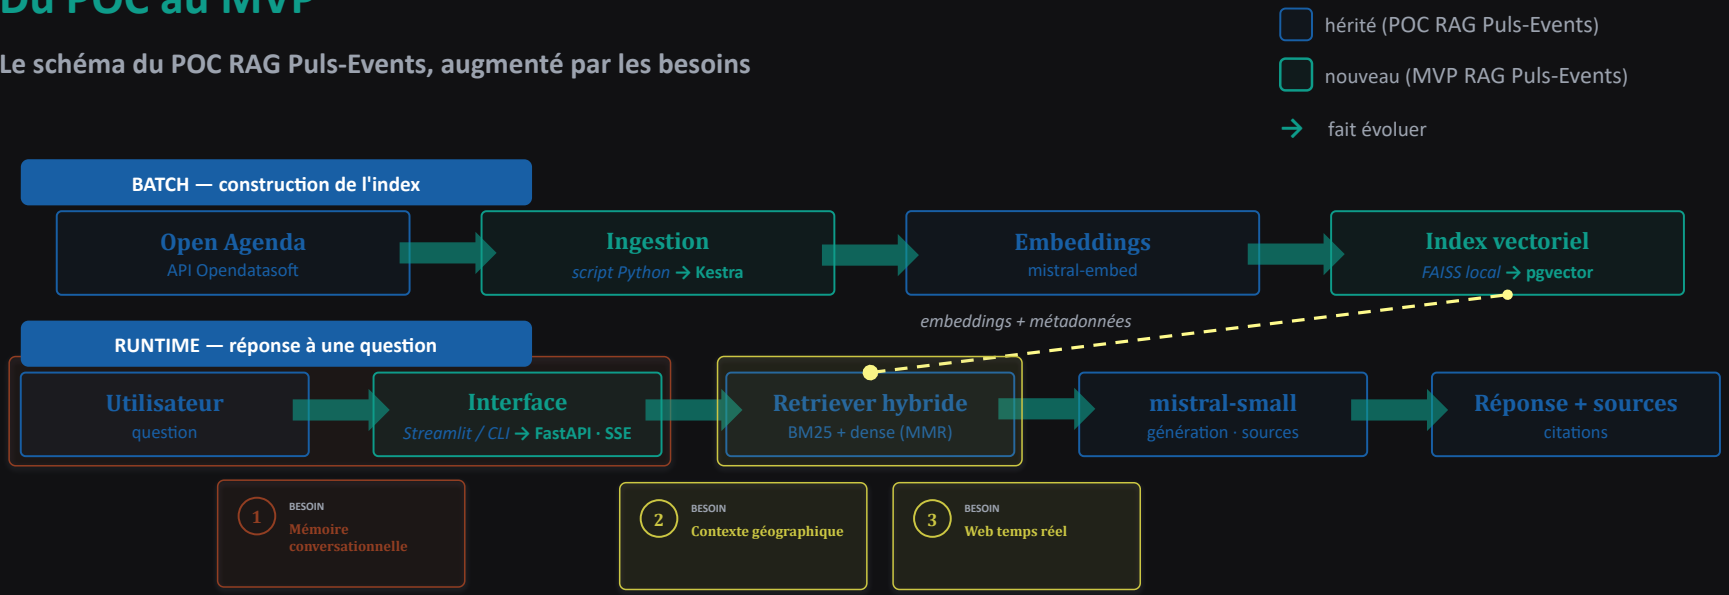
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



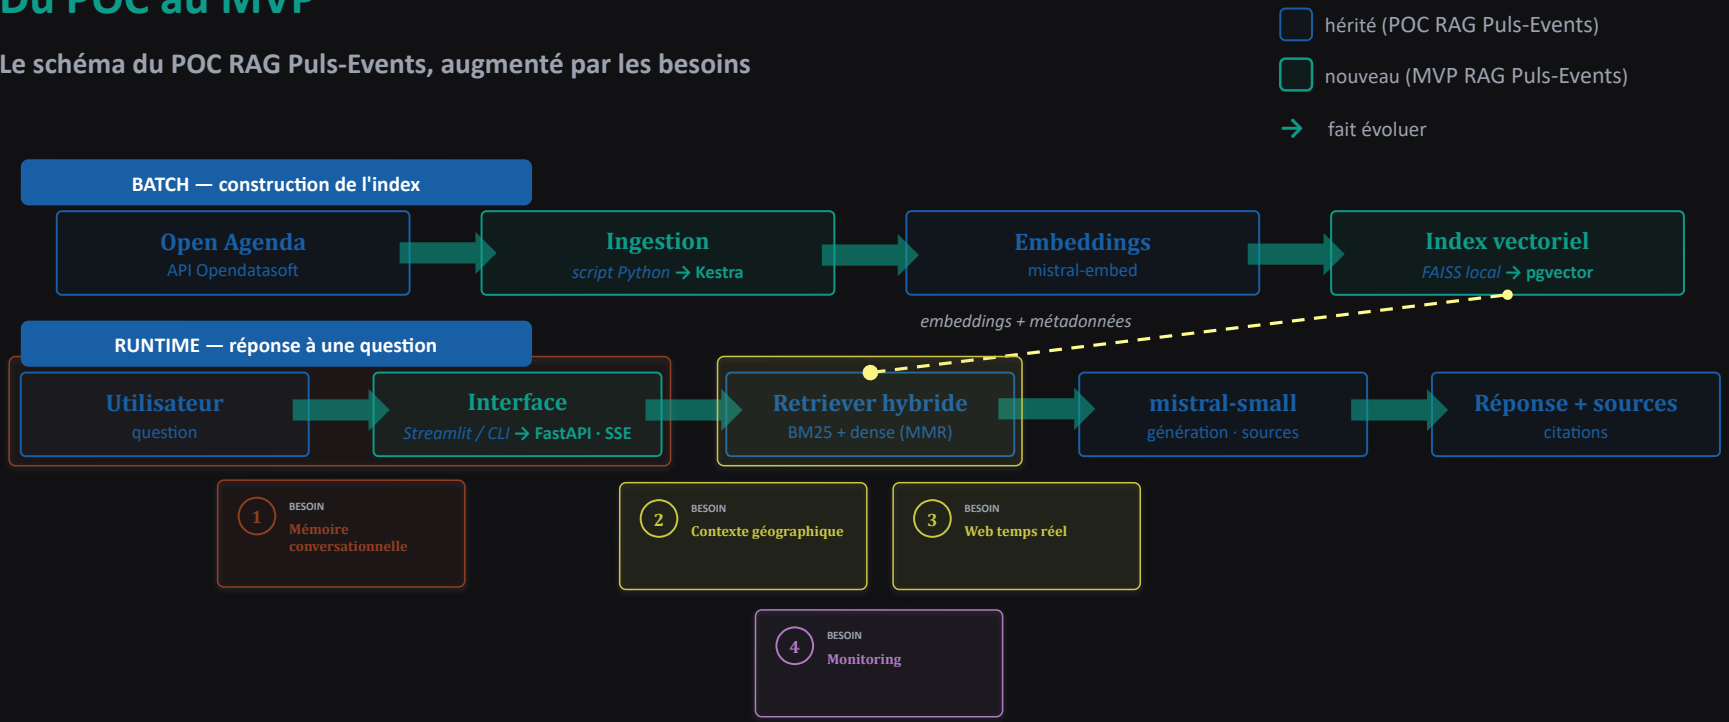
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



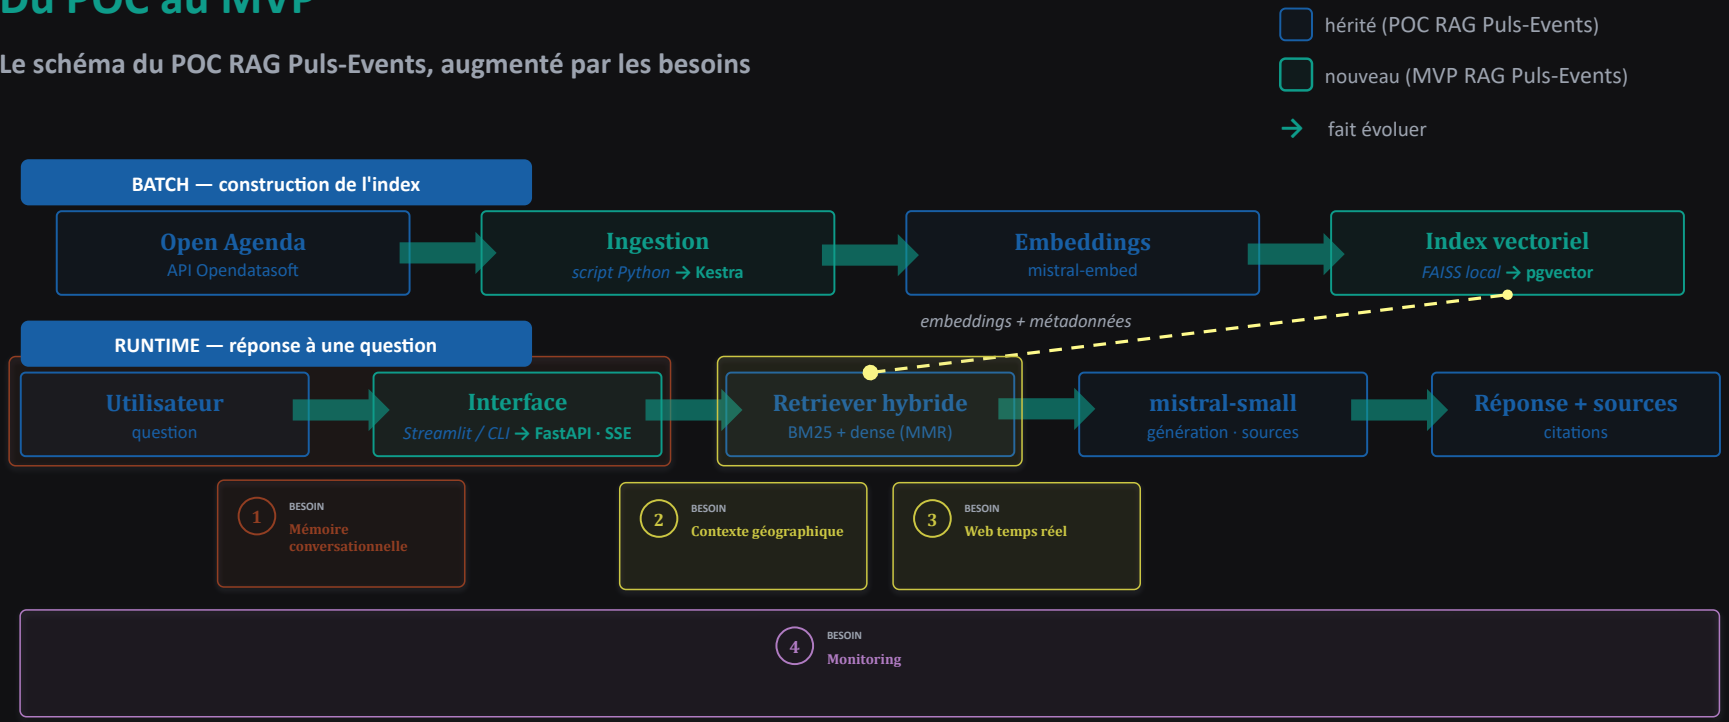
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



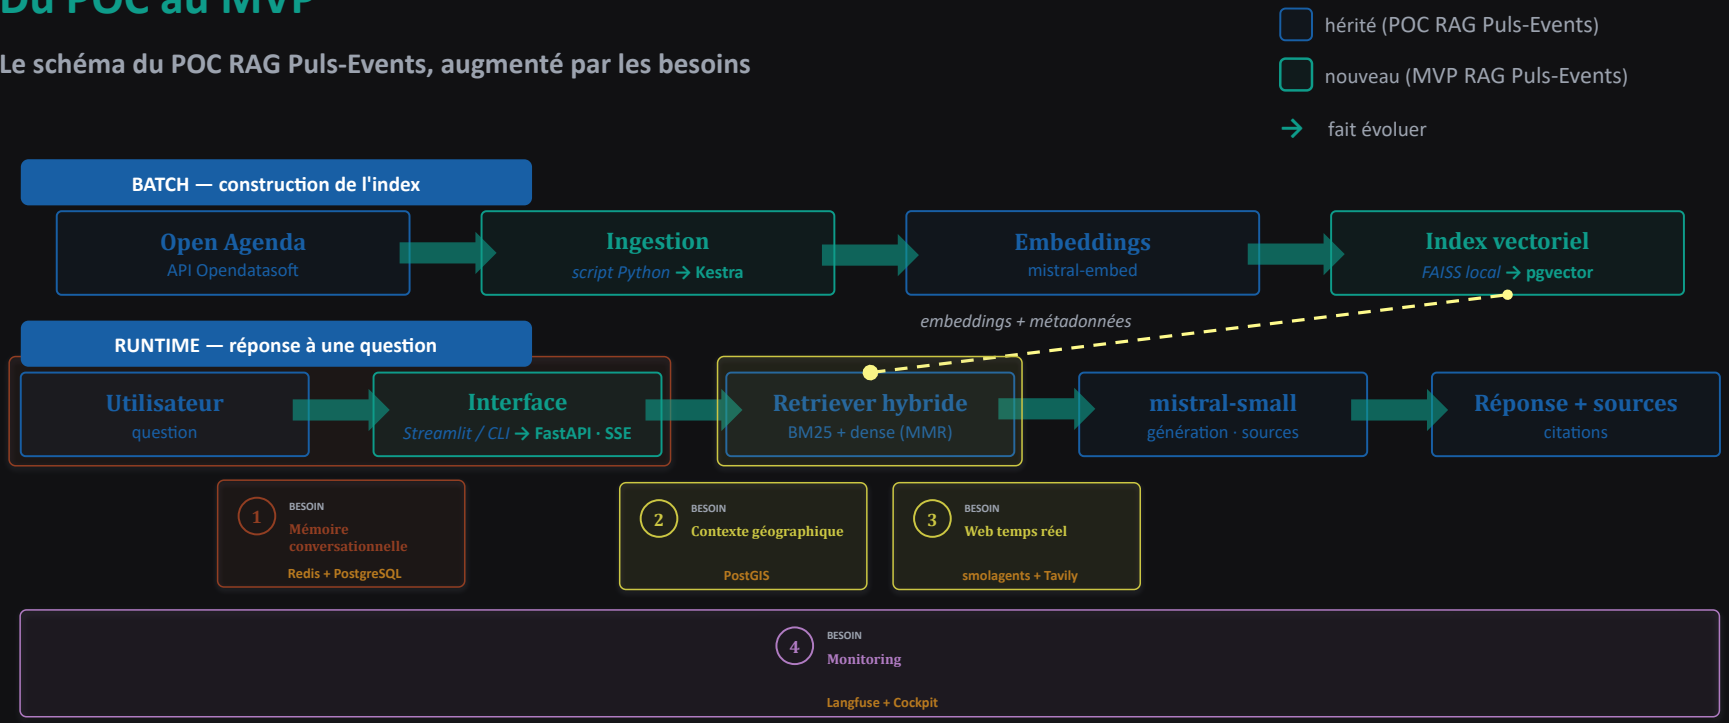
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



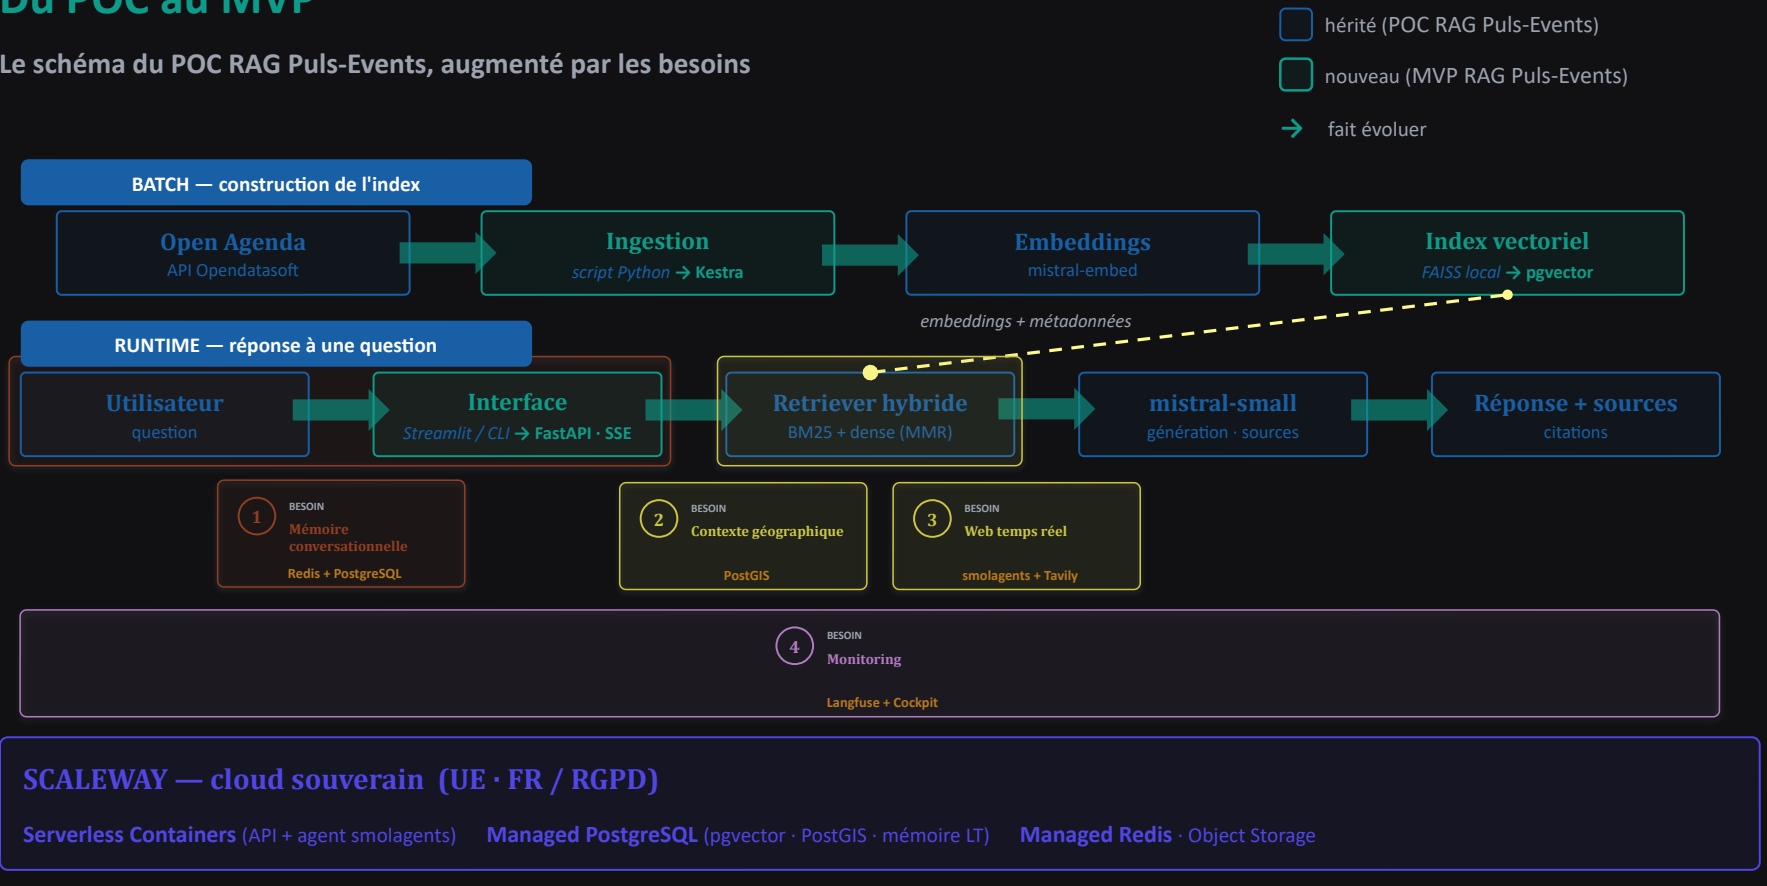
Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



Du POC au MVP

Le schéma du POC RAG Puls-Events, augmenté par les besoins



L’architecture du MVP

L'architecture en une idée : consolider

L’architecture du MVP

L'architecture en une idée : consolider

Une seule base PostgreSQL : relationnel + pgvector + PostGIS + mémoire

L’architecture du MVP

L'architecture en une idée : consolider

Une seule base PostgreSQL : relationnel + pgvector + PostGIS + mémoire

Cœur RAG du POC réutilisé (Mistral + LangChain + retriever hybride)

L’architecture du MVP

L'architecture en une idée : consolider

Une seule base PostgreSQL : relationnel + pgvector + PostGIS + mémoire

Cœur RAG du POC réutilisé (Mistral + LangChain + retriever hybride)

Agent smolagents : arbitre base interne vs recherche web

L’architecture du MVP

L'architecture en une idée : consolider

Une seule base PostgreSQL : relationnel + pgvector + PostGIS + mémoire

Cœur RAG du POC réutilisé (Mistral + LangChain + retriever hybride)

Agent smolagents : arbitre base interne vs recherche web

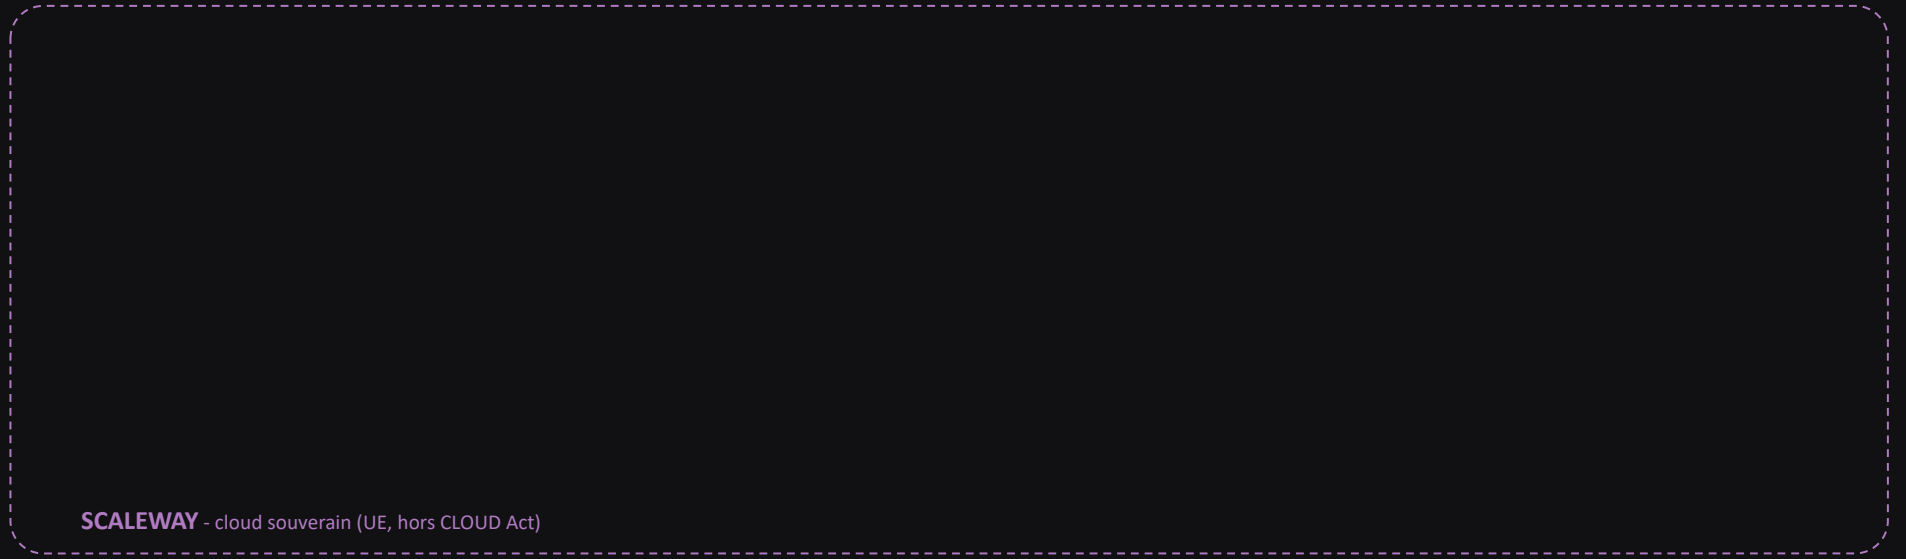
Double observabilité : Cockpit (infra) + Langfuse (qualité RAG)

L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents

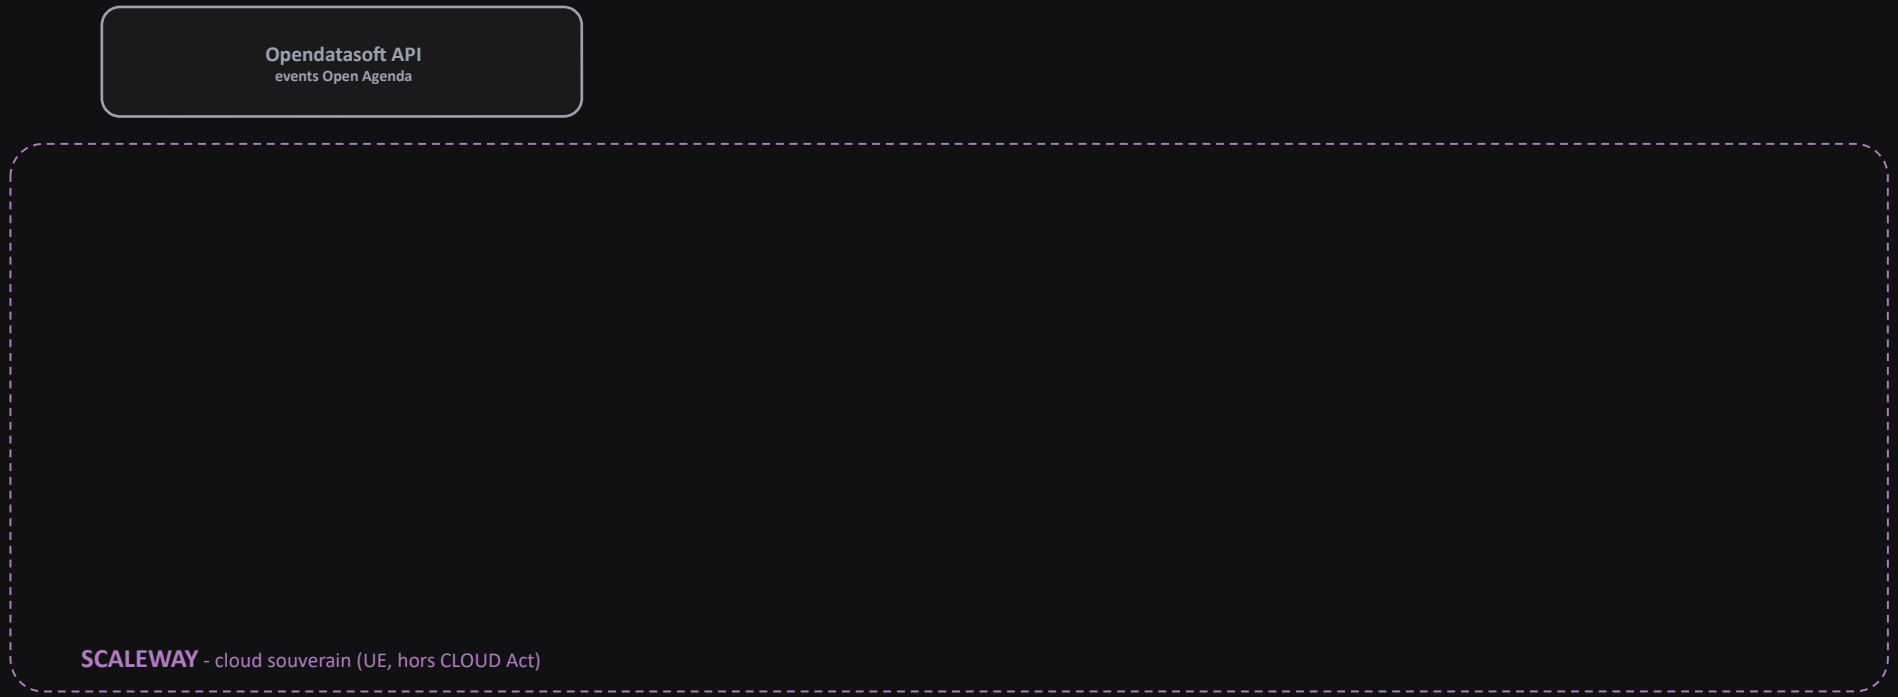
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



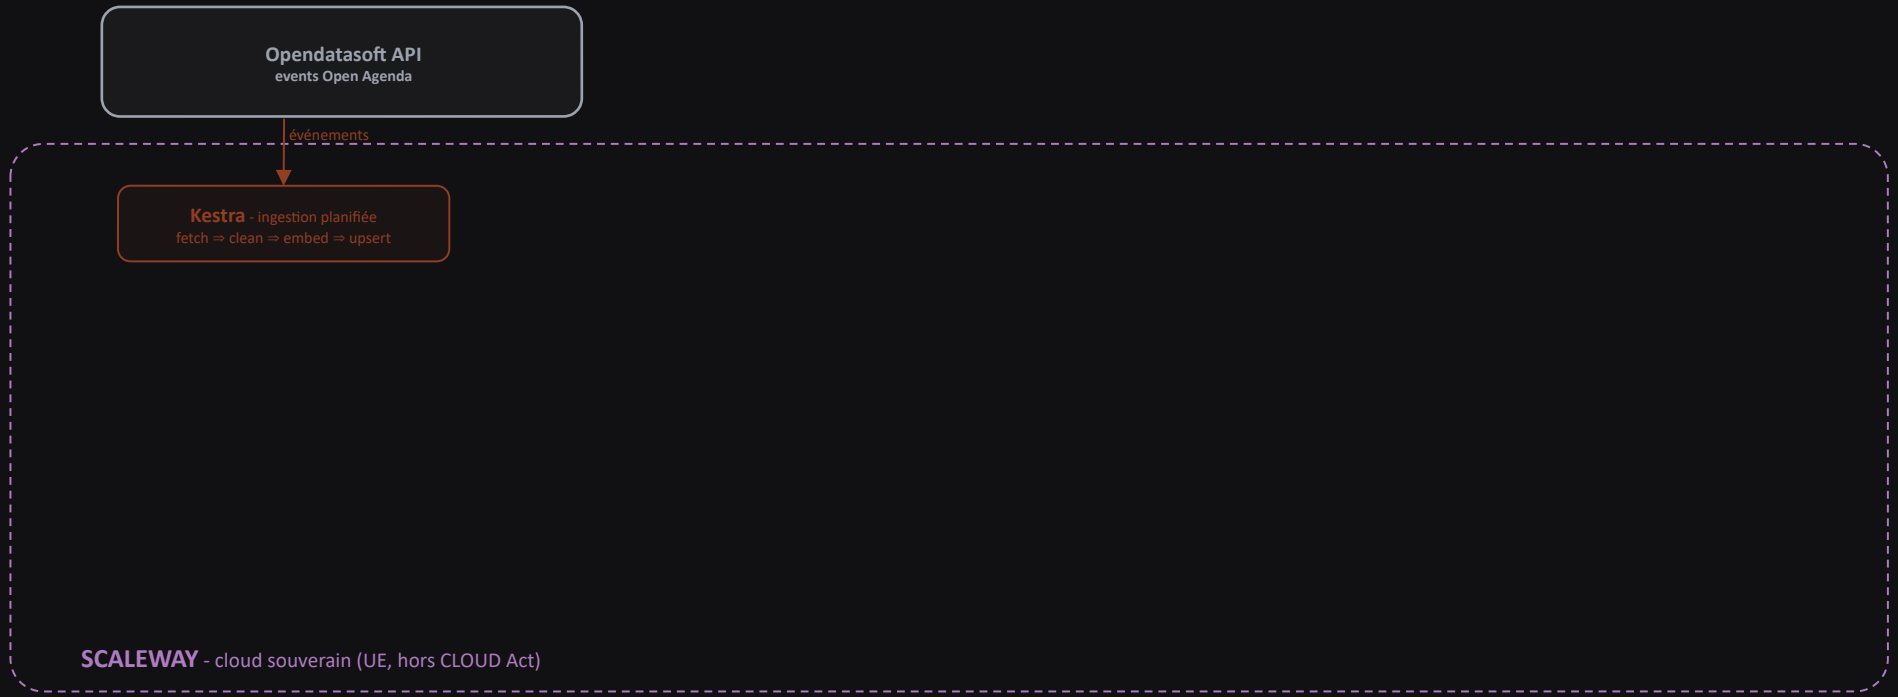
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



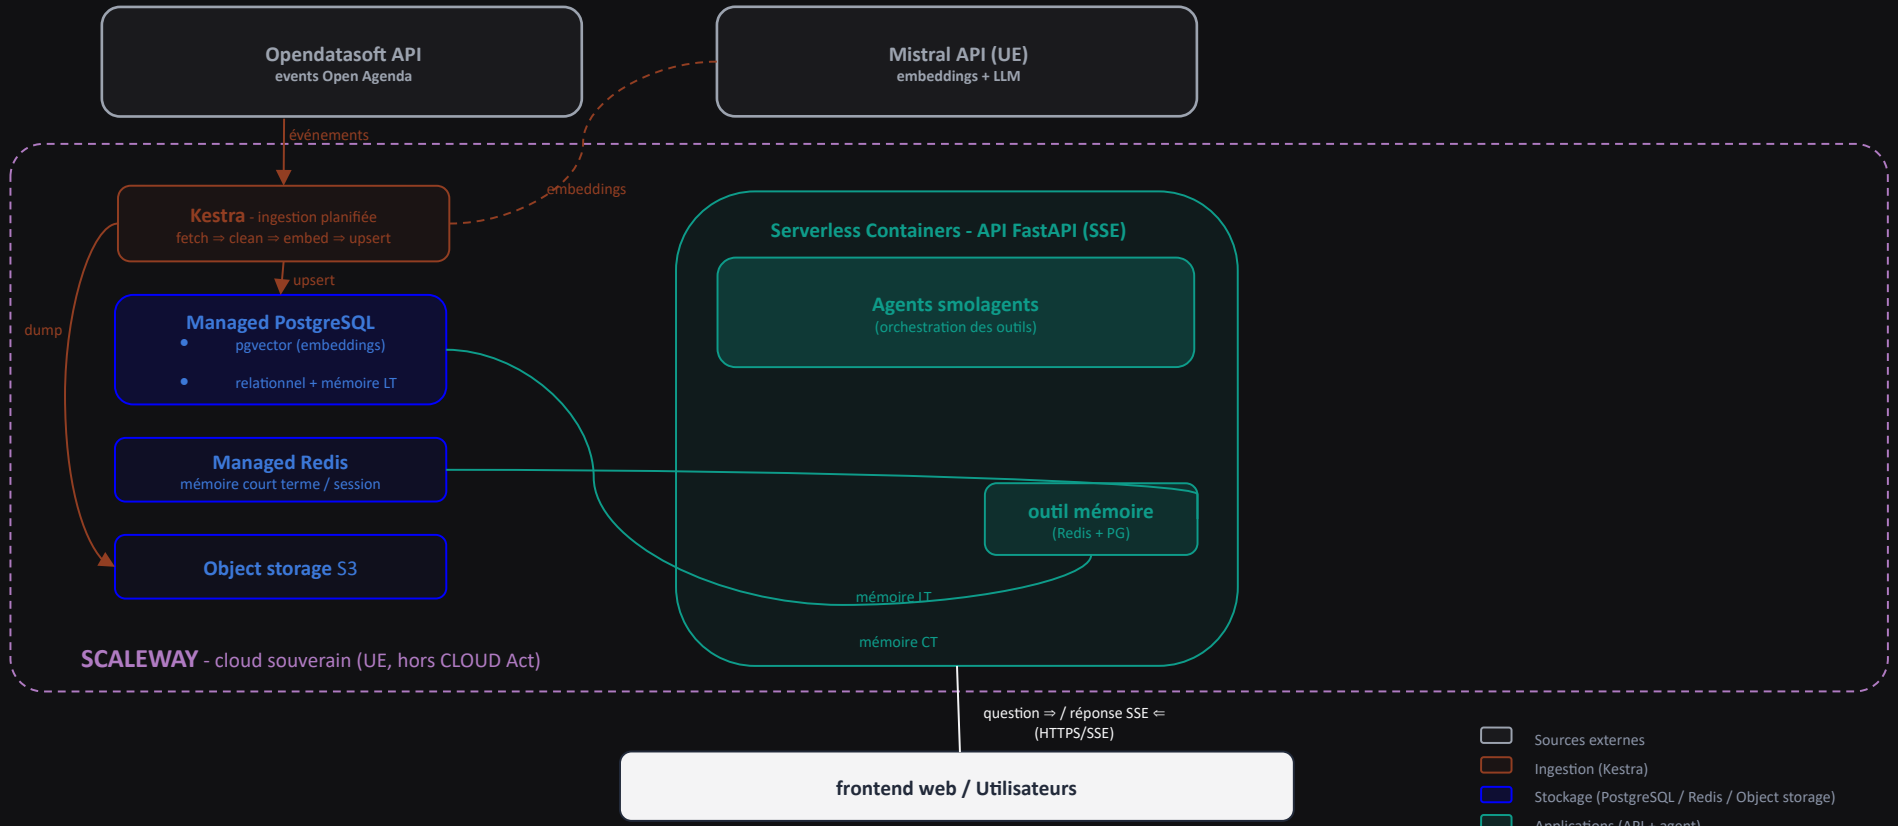
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



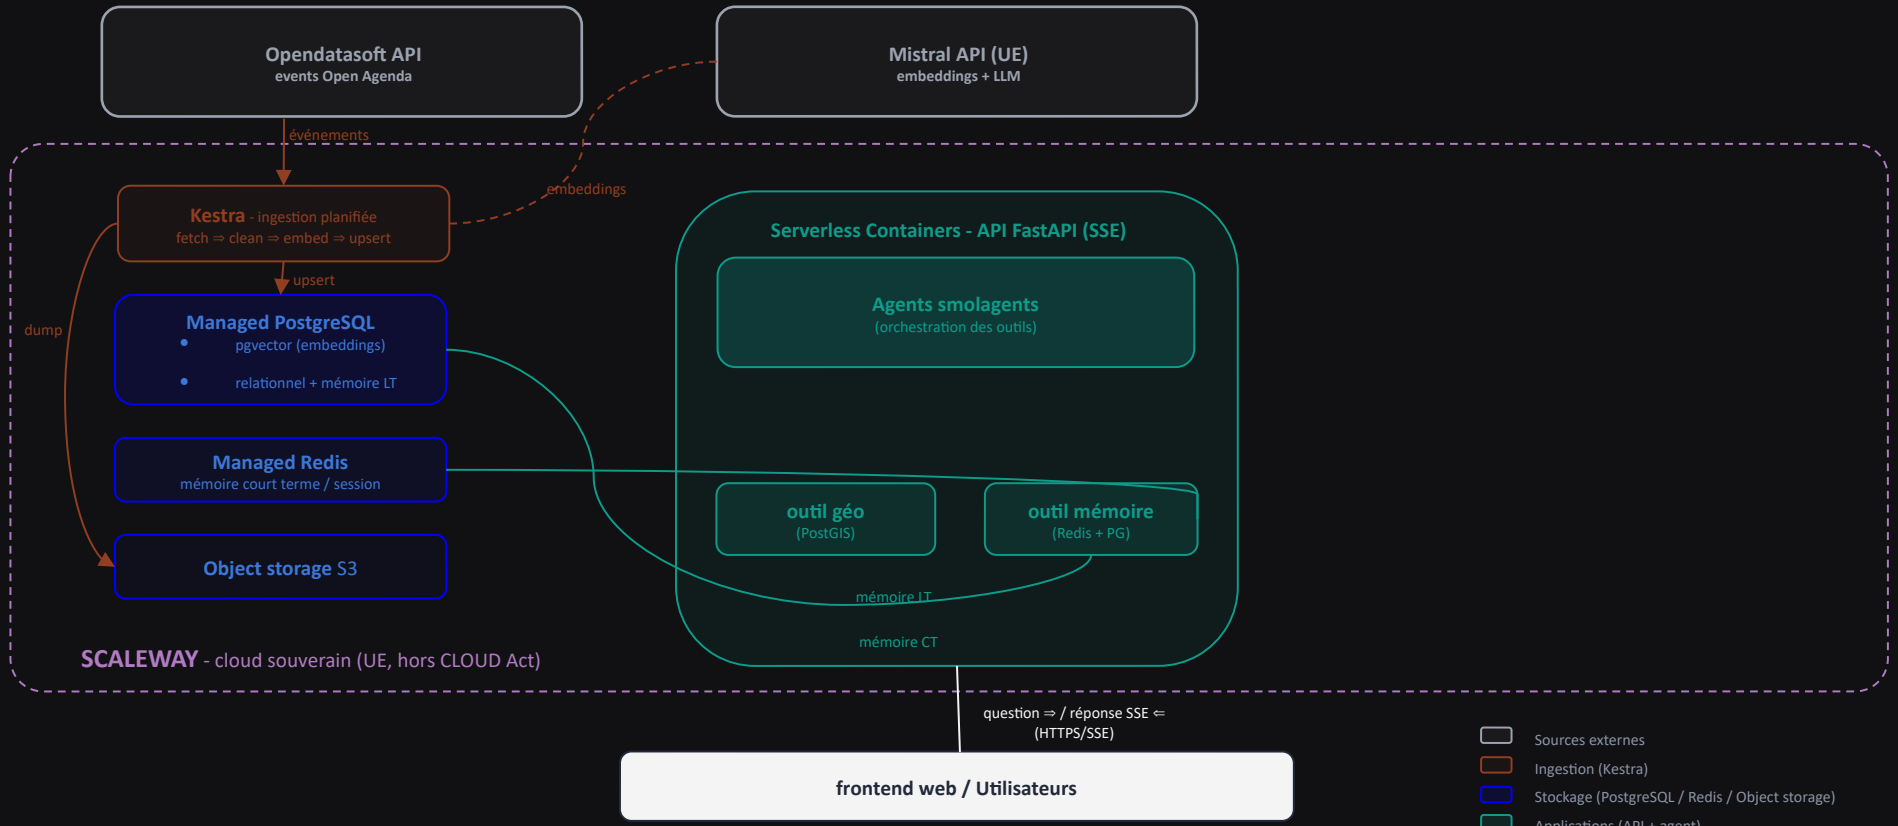
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



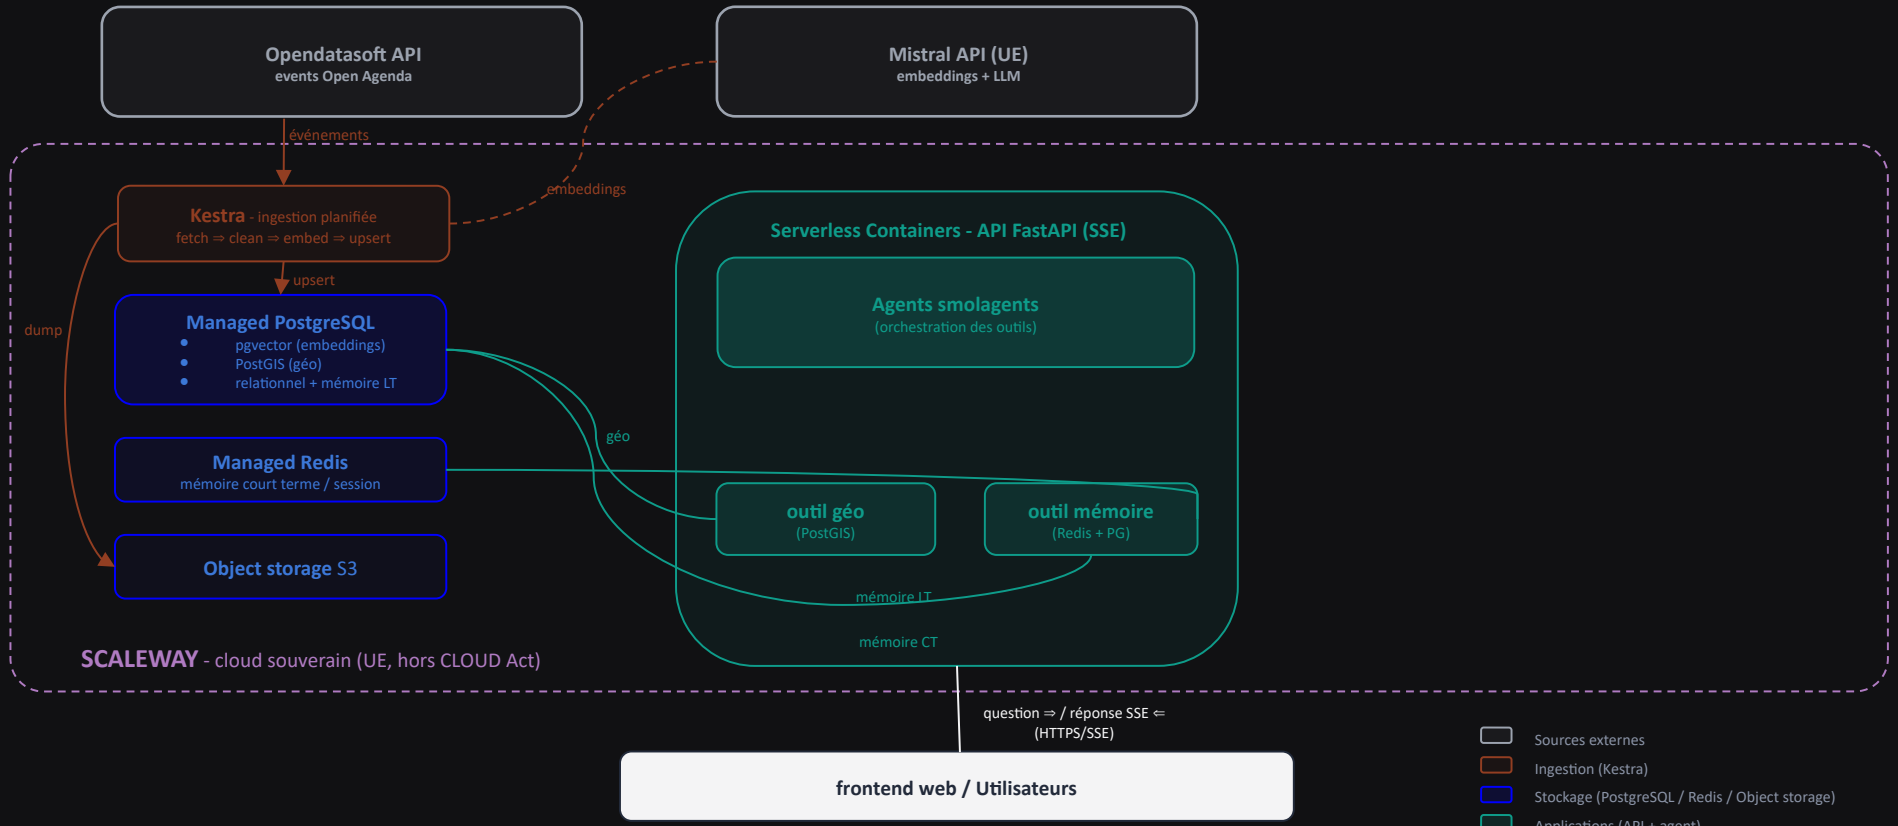
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



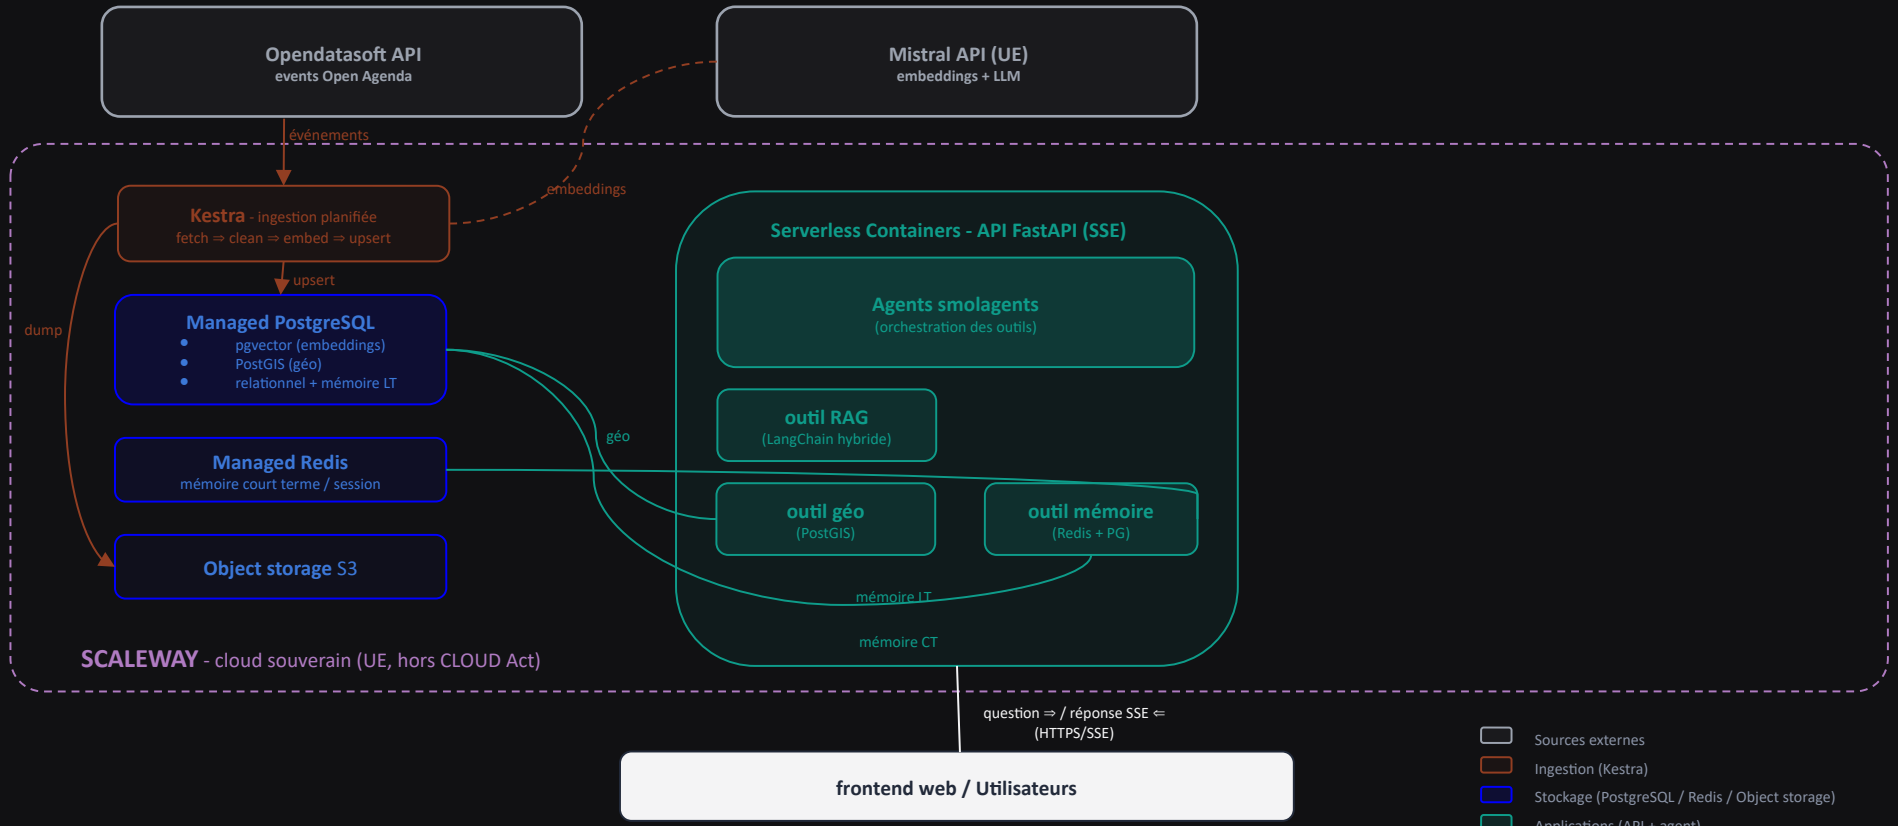
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



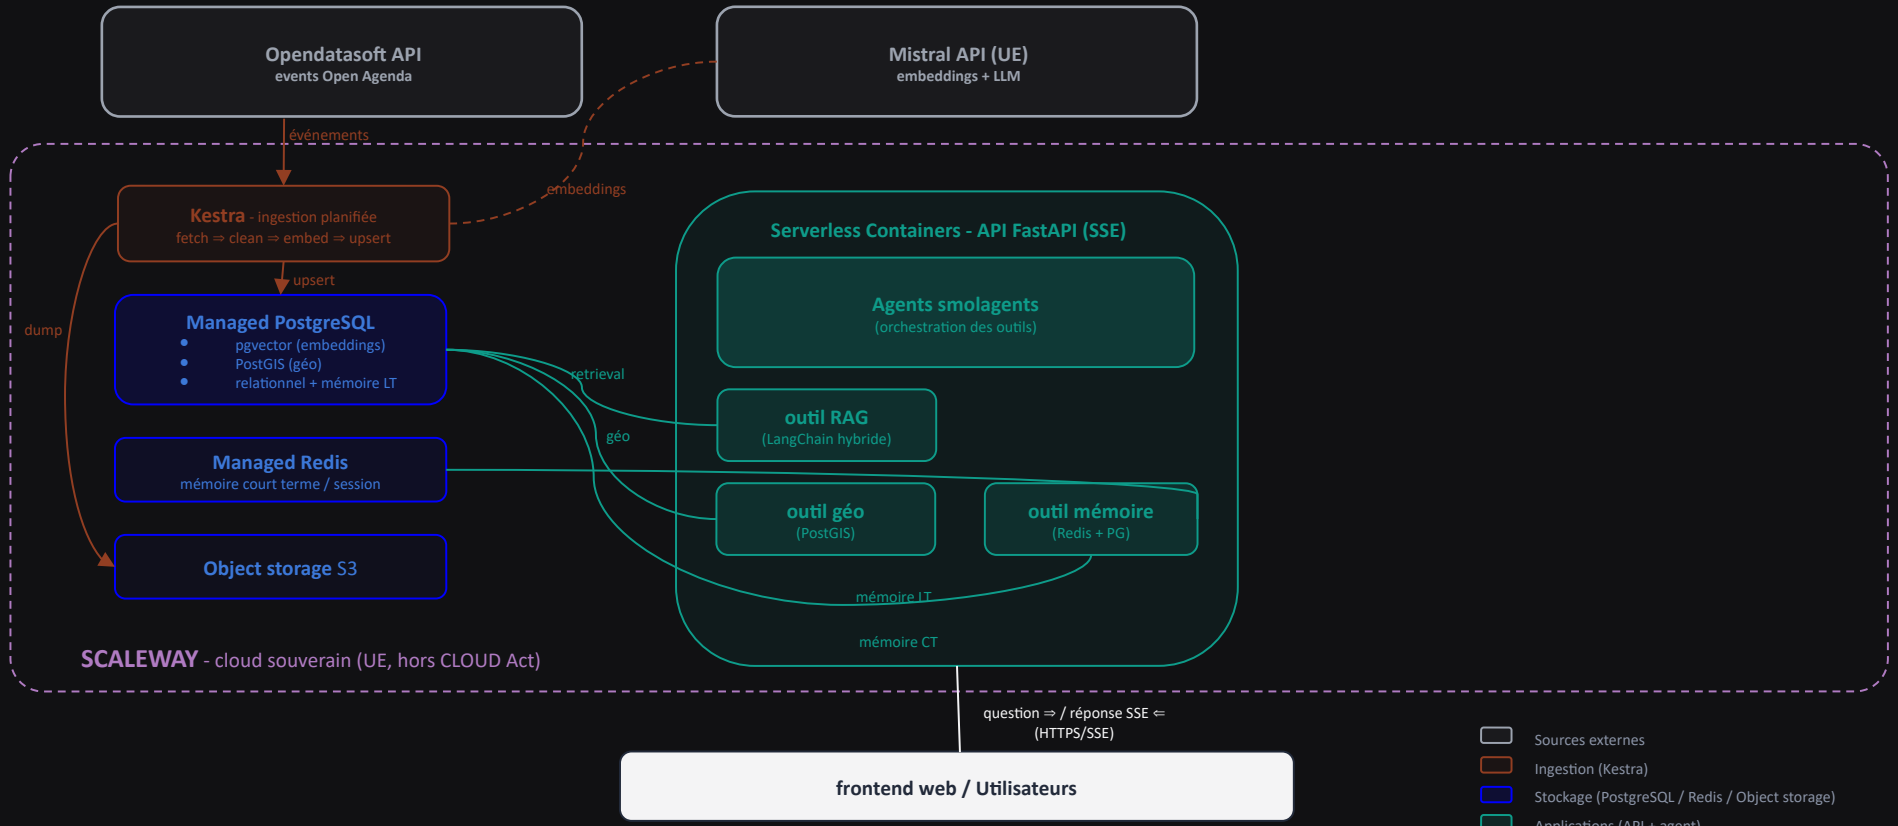
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



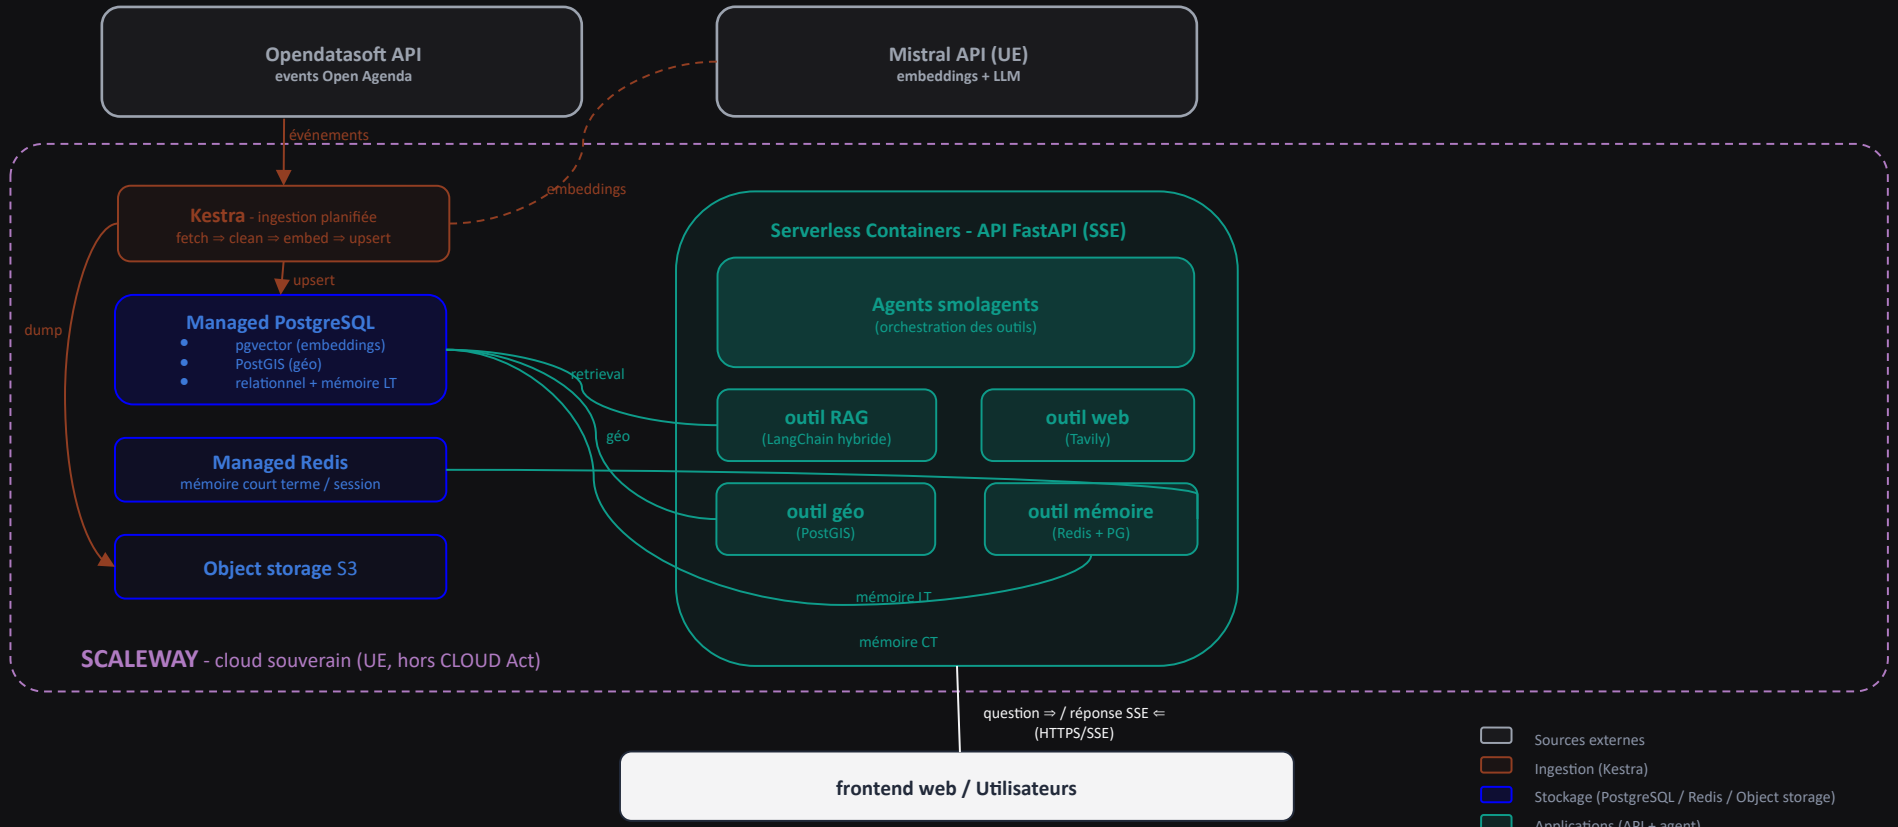
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



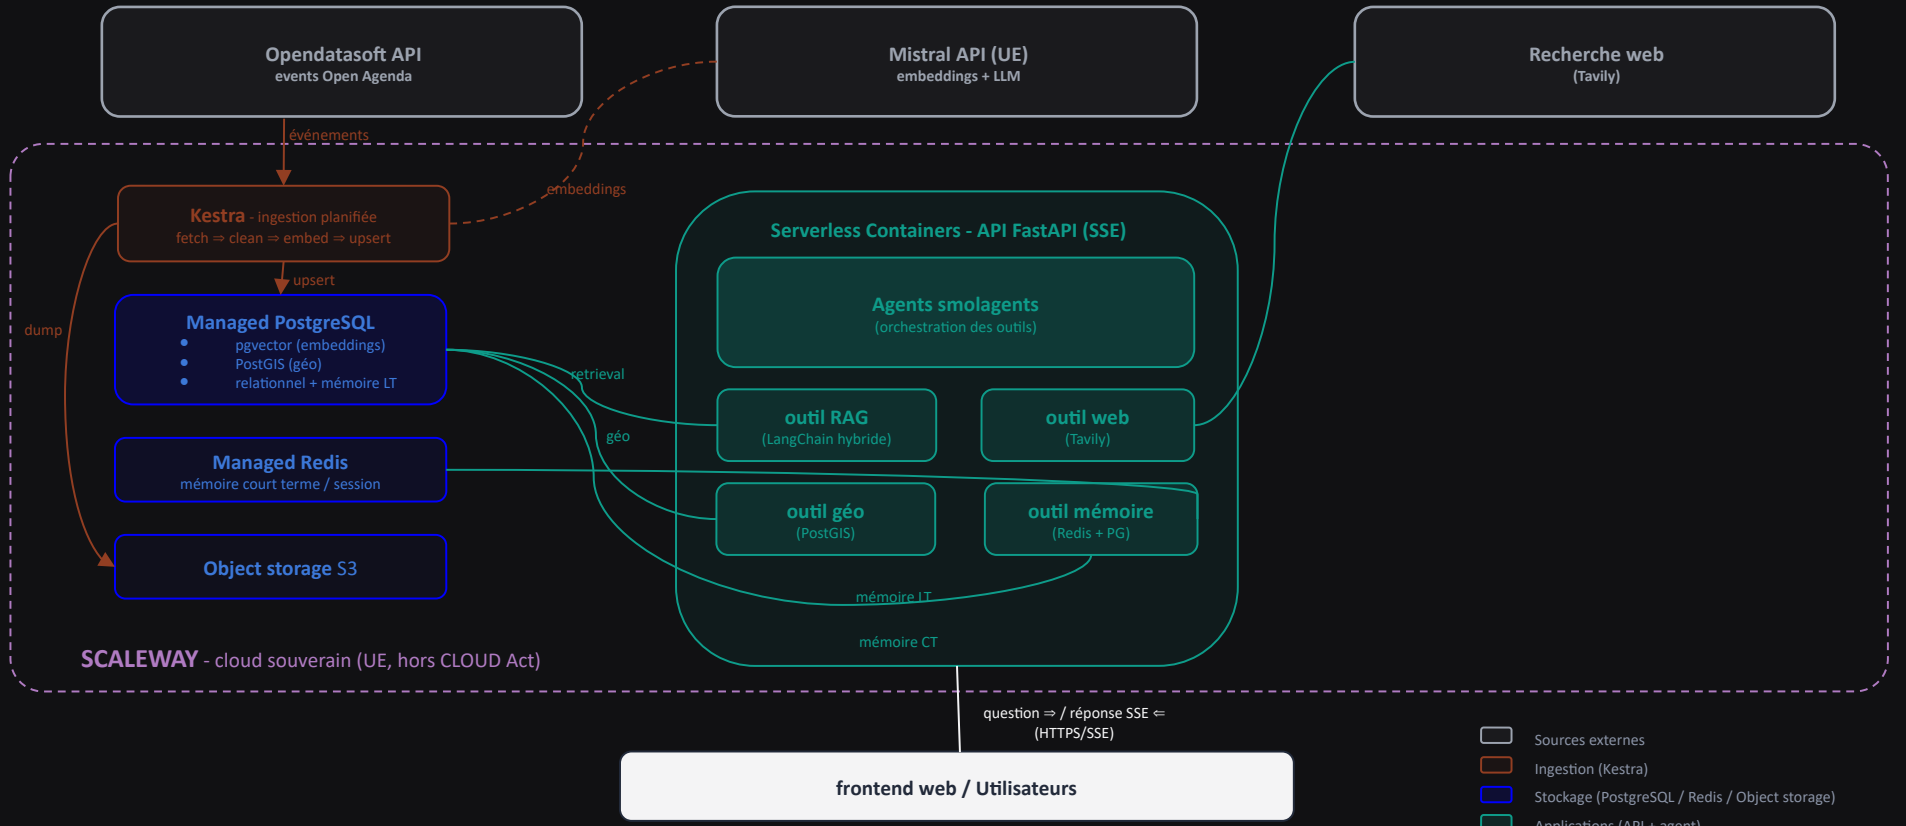
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



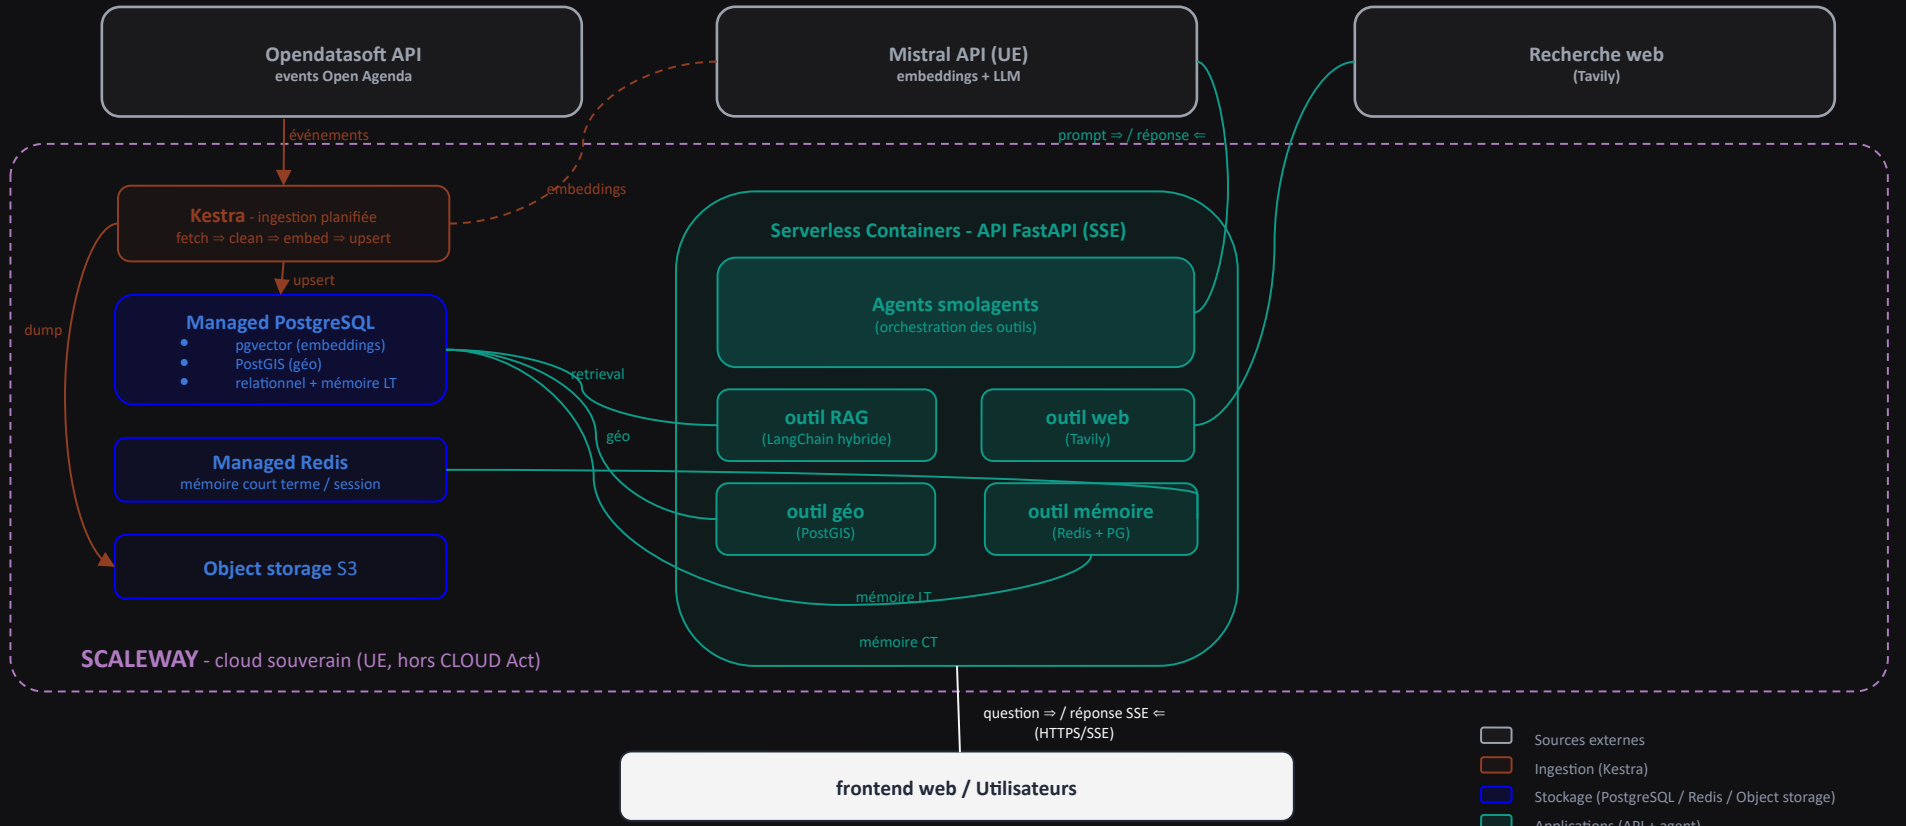
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



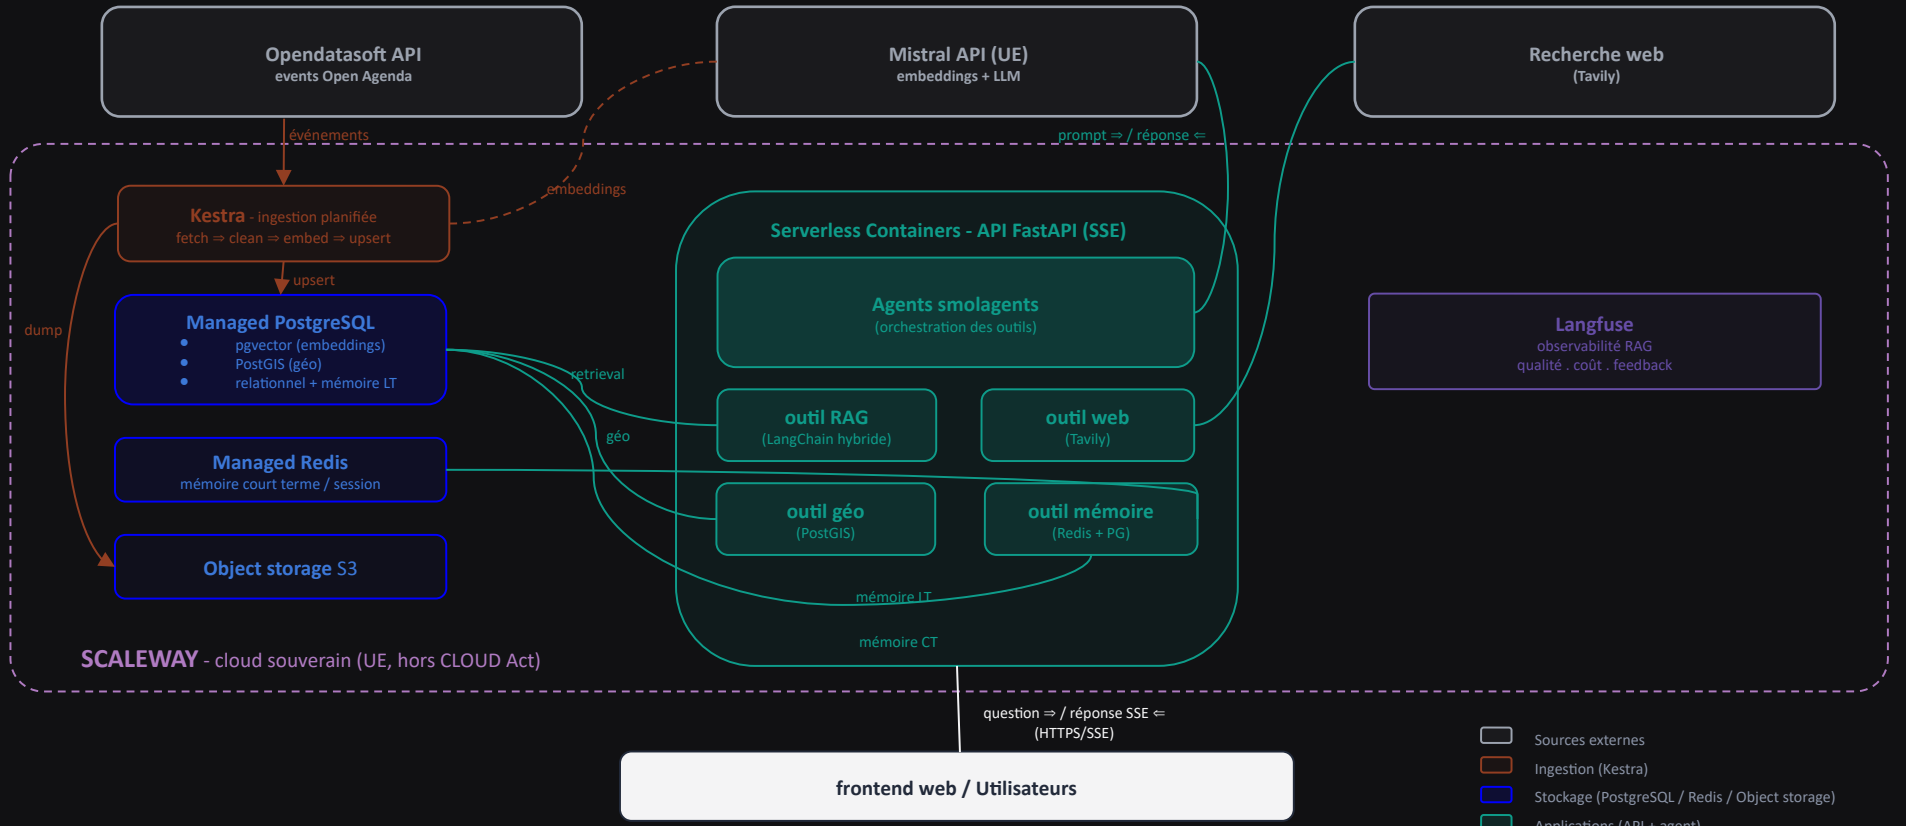
L’architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



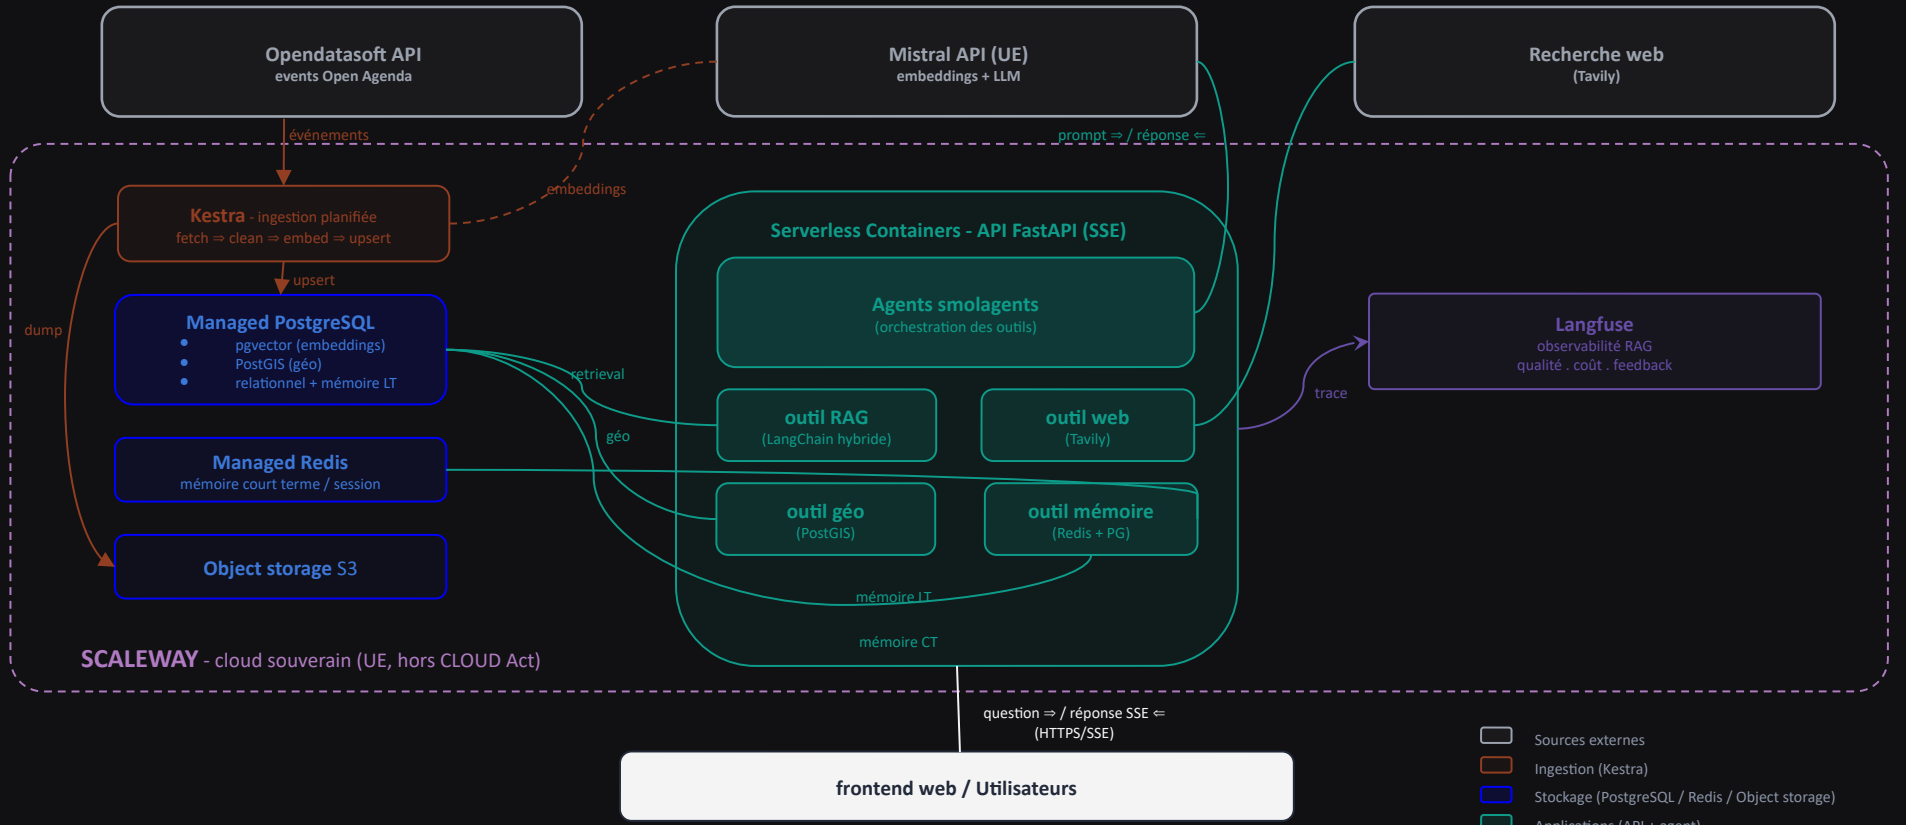
L'architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



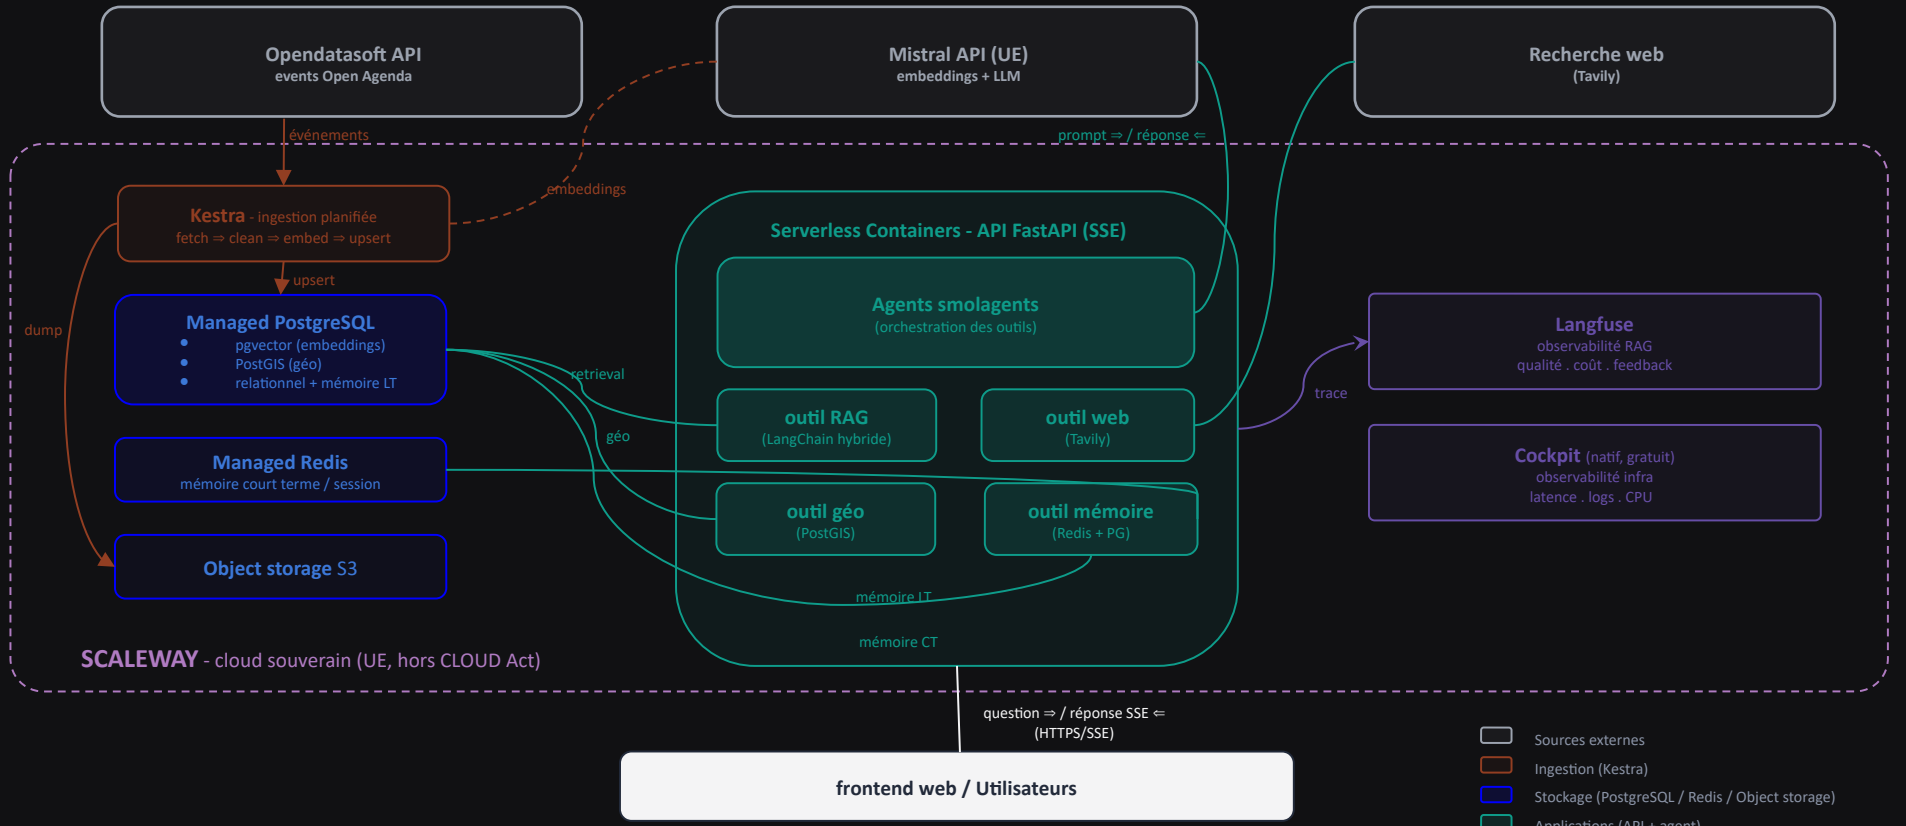
L'architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



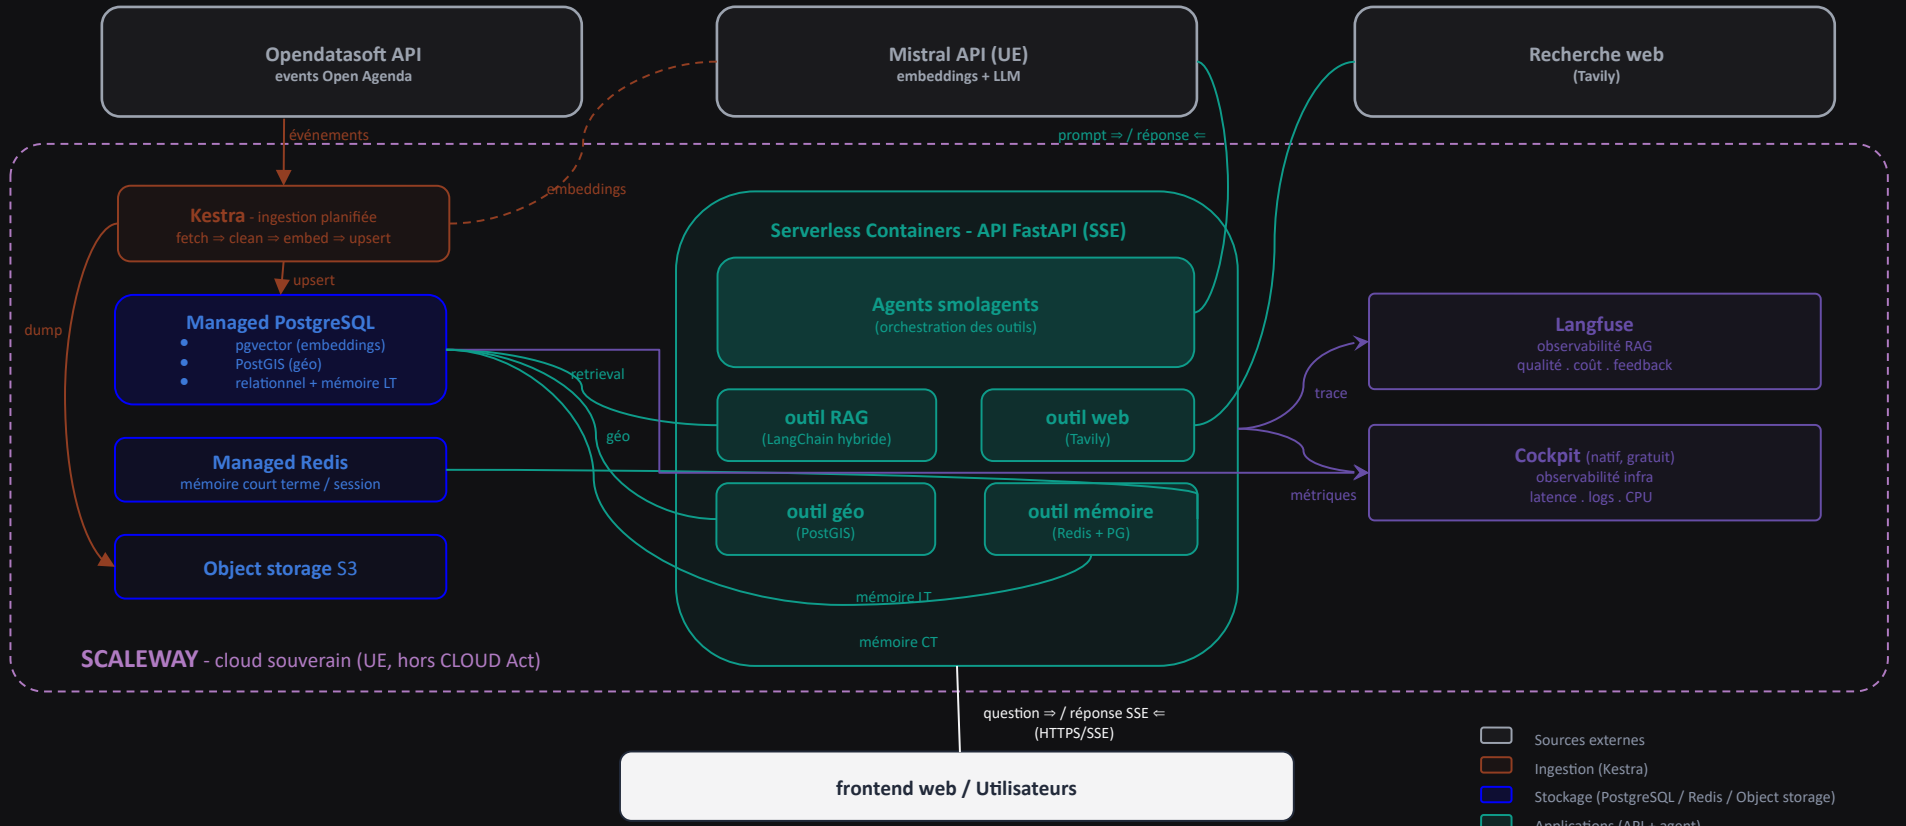
L'architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



L'architecture du MVP

Architecture MVP - chatbot RAG Puls-EVents



Justification

Un choix par défi — besoin, option, critère

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Un choix par défi — besoin, option, critère

1

Mémoire : court terme rapide + long terme durable

Redis + PostgreSQL

Critère décisif - Deux besoins de natures différentes : volatil/rapide vs durable/requêtable

Vigilance : cohérence des deux stores (TTL vs persistance)

2

Géo : requêtes rayon / distance natives

PostGIS

Critère décisif - Pousser le calcul géo dans la base, pas dans l'application

Vigilance : indexation spatiale GIST à prévoir

3

Web : compléter le RAG sur l'actualité

smolagents + Tavily

Critère décisif - Orchestration agentique légère + search pensé pour LLM (piste du brief)

Vigilance : coût par requête et latence ajoutée

4

Monitoring : qualité, coût, satisfaction

Langfuse + Cockpit

Critère décisif - Observabilité LLM-native (traces, coût, eval) + souveraineté/gratuité

Vigilance : définir les métriques tracées dès le départ

Justification

Arbitrages structurants & socle hérité

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

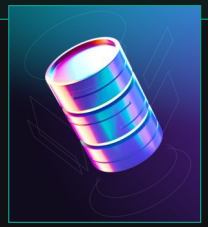
écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

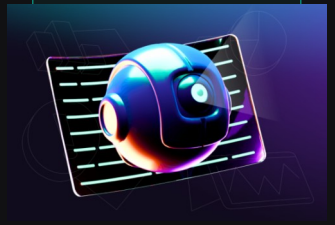
Managed PostgreSQL



Managed Redis



Cockpit



Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Justification

Arbitrages structurants & socle hérité

VECTOR STORE

écarté : FAISS · Qdrant

pgvector

Unifie vecteurs + géo + relationnel dans une seule base, moins d'ops pour un MVP.

Qdrant = plan B si la charge explose.

CLOUD

écarté : GCP · AWS · OVHcloud

Scaleway

Souveraineté FR/RGPD, juridiction UE, cohérent avec Mistral (FR).

Pas le moins cher : critère = souveraineté, assumé.

LLM + EMBEDDINGS

écarté : OpenAI · self-hosted

Mistral

Hérité et validé en RAG Puls-Events, FR/RGPD, abstrait via LangChain.

Remplaçable sans réécrire le RAG.

Socle hérité — sans arbitrage

FastAPI (async + SSE) **LangChain (RAG hybride réutilisé)** **Kestra (ingestion, maîtrisé)**

Monitoring

Quelles métriques, et où les mesurer

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Coût

€ par requête
le chiffre clé

Tokens in / out
décompose le coût

Coût / jour & / user
projection à l'échelle

LLM / embed / web
répartition

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Coût

€ par requête
le chiffre clé

Tokens in / out
décompose le coût

Coût / jour & / user
projection à l'échelle

LLM / embed / web
répartition

Satisfaction

Feedback + / –
explicite (pouce)

Clic sur sources
confiance

Reformulations
signal implicite

Abandon / durée
engagement

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Coût

€ par requête
le chiffre clé

Tokens in / out
décompose le coût

Coût / jour & / user
projection à l'échelle

LLM / embed / web
répartition

Satisfaction

Feedback + / –
explicite (pouce)

Clic sur sources
confiance

Reformulations
signal implicite

Abandon / durée
engagement

Technique

Time-to-first-token
latence perçue (SSE)

Latence p50 / p95
la queue = pannes

Taux d'erreur
5xx, timeouts LLM

Infra (Cockpit)
CPU/RAM, Redis, PG

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Coût

€ par requête
le chiffre clé

Tokens in / out
décompose le coût

Coût / jour & / user
projection à l'échelle

LLM / embed / web
répartition

Satisfaction

Feedback + / –
explicite (pouce)

Clic sur sources
confiance

Reformulations
signal implicite

Abandon / durée
engagement

Technique

Time-to-first-token
latence perçue (SSE)

Latence p50 / p95
la queue = pannes

Taux d'erreur
5xx, timeouts LLM

Infra (Cockpit)
CPU/RAM, Redis, PG

Langfuse → qualité · coût · feedback (LLM / RAG) **Cockpit** → infra Scaleway (conteneurs, ressources)

Monitoring

Quelles métriques, et où les mesurer

Qualité du RAG

Faithfulness
LLM-juge, échantillonné

Answer relevancy
pertinence réponse

Recall@k / MRR
offline, déjà outillé

Taux de « je ne sais pas »
comptage simple

Coût

€ par requête
le chiffre clé

Tokens in / out
décompose le coût

Coût / jour & / user
projection à l'échelle

LLM / embed / web
répartition

Satisfaction

Feedback + / –
explicite (pouce)

Clic sur sources
confiance

Reformulations
signal implicite

Abandon / durée
engagement

Technique

Time-to-first-token
latence perçue (SSE)

Latence p50 / p95
la queue = pannes

Taux d'erreur
5xx, timeouts LLM

Infra (Cockpit)
CPU/RAM, Redis, PG

Langfuse → qualité · coût · feedback (LLM / RAG) **Cockpit** → infra Scaleway (conteneurs, ressources)

Starter MVP — 6 métriques à instrumenter dès la Phase 3

€ / requête | Latence p95 | Taux d'erreur | Faithfulness | Feedback + / – | Recall@k

Pilotage

Délais & budget

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

0

Phase 0 - Socle & infra ~2 sem

Docker, Scaleway, Postgres (pgvector + PostGIS)

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

0 — **Phase 0 - Socle & infra** — ~2 sem
Docker, Scaleway, Postgres (pgvector + PostGIS)

1 — **Phase 1 - Mémoire + Géo** — ~3 sem
Redis + Postgres LT, requêtes PostGIS

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

0 — **Phase 0 - Socle & infra** — ~2 sem
Docker, Scaleway, Postgres (pgvector + PostGIS)

1 — **Phase 1 - Mémoire + Géo** — ~3 sem
Redis + Postgres LT, requêtes PostGIS

2 — **Phase 2 - Web + API** — ~3 sem
smolagents + Tavily, API FastAPI SSE

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

0 — **Phase 0 - Socle & infra** — ~2 sem
Docker, Scaleway, Postgres (pgvector + PostGIS)

1 — **Phase 1 - Mémoire + Géo** — ~3 sem
Redis + Postgres LT, requêtes PostGIS

2 — **Phase 2 - Web + API** — ~3 sem
smolagents + Tavily, API FastAPI SSE

3 — **Phase 3 - Monitoring** — ~2 sem
Langfuse, métriques, durcissement

Pilotage

Délais & budget

Phasage — estimation ~10 semaines

0	**Phase 0 - Socle & infra** Docker, Scaleway, Postgres (pgvector + PostGIS)	~2 sem
1	**Phase 1 - Mémoire + Géo** Redis + Postgres LT, requêtes PostGIS	~3 sem
2	**Phase 2 - Web + API** smolagents + Tavily, API FastAPI SSE	~3 sem
3	**Phase 3 - Monitoring** Langfuse, métriques, durcissement	~2 sem

Budget — estimation ~ 160 € / mois

Hyp. : 1 000 req/j · ~4k tokens/req · 20 % via web · Postgres non-HA

Mistral — génération mistral-small · 105M in + 15M out	~14 €
Mistral — embeddings requêtes + ré-indexation	~2 €
Tavily — recherche web ~6 000 recherches / mois	~40 €
Scaleway — PostgreSQL managé, prod non-HA (PRO2-XXS)	~80 €
Scaleway — Serverless + Redis conteneurs à l'usage	~25 €
Langfuse + Cockpit self-host / natif Scaleway	gratuit
Total estimé	~160 €

Dominé par l'infra fixe à ce volume — le LLM ne pèse que ~10 % mais scale avec le trafic. HA Postgres double la base. Grilles juin 2026, à valider.

Synthèse

Un MVP souverain, justifié défi par défi

Synthèse

Un MVP souverain, justifié défi par défi

- **4 défis couverts -** une techno par défi, chaque choix tracé jusqu'à un besoin

Synthèse

Un MVP souverain, justifié défi par défi

- **4 défis couverts -** une techno par défi, chaque choix tracé jusqu'à un besoin
- **Stack souveraine -** Scaleway + Mistral, FR / RGPD de bout en bout

Synthèse

Un MVP souverain, justifié défi par défi

- **4 défis couverts -** une techno par défi, chaque choix tracé jusqu'à un besoin
- **Stack souveraine -** Scaleway + Mistral, FR / RGPD de bout en bout
- **pgvector unifie -** vecteurs + géo + relationnel dans une seule base pour le MVP

Synthèse

Un MVP souverain, justifié défi par défi

- **4 défis couverts -** une techno par défi, chaque choix tracé jusqu'à un besoin
- **Stack souveraine -** Scaleway + Mistral, FR / RGPD de bout en bout
- **pgvector unifie -** vecteurs + géo + relationnel dans une seule base pour le MVP
- **Socle réutilisé -** LangChain + RAG hybride du POC Puls-Events, on ne réinvente pas

Synthèse

Un MVP souverain, justifié défi par défi

- **4 défis couverts -** une techno par défi, chaque choix tracé jusqu'à un besoin
- **Stack souveraine -** Scaleway + Mistral, FR / RGPD de bout en bout
- **pgvector unifie -** vecteurs + géo + relationnel dans une seule base pour le MVP
- **Socle réutilisé -** LangChain + RAG hybride du POC Puls-Events, on ne réinvente pas

Prochaine étape → valider les hypothèses de budget, puis lancer la Phase 0 (socle & infra)